中国研究生网络安全创新大赛
作品报告

作品名称：SSIR：一种通过图像-密钥控制的 DNN 状态实现安全隐秘信息表示的框架

提交日期：2026 年 10 月 21 日

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。

2. 作品报告采用 A4 纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5 倍行距。

3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）

4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。

5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。一经发现，取消作品参赛资格。

目录

摘要 1

第一章 作品概述 2

1.1 项目背景 2

1.2 相关工作 3

1.3 作品特色 3

1.4 应用前景分析 5

第二章 作品设计与实现 6

2.1 系统方案 6

2.1.1 系统模型 6

2.1.2 设计目标与阶段划分 8

2.2 实现原理 9

2.3 系统流程 12

2.4 功能模块 14

2.5 性能指标 14

第三章 作品测试与分析 17

3.1 测试方案 17

3.2 测试环境搭建 17

3.3 测试设备 18

3.4 测试功能 18

3.5 结果分析 23

3.6 安全性分析 23

3.6.1 用于密钥控制表示的 DNN 非线性 24

3.6.2 概率生成与多语义 25

3.6.3 形式化安全分析 26

第四章 创新性说明 28

4.1 原理创新 28

4.2 性能创新 28
4.3 安全与部署创新 28
第五章 总结 30
参考文献 31
附录 34

摘要

在数据驱动的社会背景下，数据非法获取、篡改或泄露的风险显著增加，不仅威胁个人财产安全，还可能影响社会稳定和国家安全。传统加密技术虽然能够保护数据传输内容，却难以隐藏通信行为本身。相比之下，图像隐写技术虽然能够隐藏秘密信息和通信行为的存在性，但部分基于深度学习的方案依赖专用模型训练或额外组件，增加了部署成本。针对这些问题，受深度神经网络（Deep Neural Network，DNN）和密码学融合启发，本文提出一种基于图像密钥控制 DNN 状态的安全隐蔽信息表示框架（Secure and Stealthy Information Representation，SSIR）。

该框架的发送方和接收方预先共享密钥。发送方首先使用分组编码将消息标识为现有 DNN 中选定神经的目标状态，随后结合共享密钥，通过对抗优化生成能够诱导目标状态的密文图像。接收方将密文图像与共享密钥融合后输入相同的 DNN，通过解码神经元状态恢复原始消息。由于密文图像可能存在直接视觉泄露和间接 DNN 状态泄露风险，方案设计了联合损失优化机制，以抑制图像中的可检测信息痕迹。进一步，我们从理论上分析了 SSIR 的安全性。针对查询有界攻击者，分别推到其 IND-CPA 与 IND-CCA1 优势界，并给出有界查询安全所需的分布条件与每密钥查询次数限制。

与依赖专用模型训练的部分现有方法相比，SSIR 无需修改 DNN 参数或进行额外模型训练，即可利用现有模型完成信息表示与恢复，并保留其原有功能。实验基于 ImageNet 数据集和真实图像，从消息恢复可靠性、信息泄漏抑制、攻击鲁棒性、运行效率和模型兼容性等方面对方案进行评估。实验结果表明，分组编码将所测配置下的生成成功率由 79% 提高至 100%; 通过调整优化参数，直接视觉泄漏代理指标最高降低 99.79%，启用间接泄漏约束后，神经元状态偏差平均降低 56.02%; 对于 150 位消息，密文图像生成时间约为 300 ~ 500 ms，消息恢复时间约为 10 ms。SSIR 能够适配多种常见 DNN，并且保持模型原有功能。通过分析不同分组大小和学习率对生成成功率，图像质量及生成时间的影响，为实际应用中的参数选择提供了参考。

关键词： 深度神经网络；信息安全；隐蔽信息传输；对抗样本

第一章　作品概述

1.1　项目背景

随着信息技术的发展，数据安全不仅关系到个人隐私和企业商业秘密，也是国家安全的重要组成部分。传统数据加密技术已广泛应用于信息传输领域，能够有效保护传输内容，但难以隐藏通信行为本身。在实际网络环境中，即使通信内容经过加密，第三方仍然可能通过分析通信时间、流量大小等推测用户通信关系以及活动规律，从而造成隐私泄露。因此，数据传输不仅需要保障信息内容的安全性，还需要关注敏感信息传输的隐蔽性。

为满足这一要求，图像隐写术通过将秘密信息隐藏在自然图像中，降低敏感信息传输被发现的可能性[1-2]。然而，部分基于深度学习的图像隐写方案需要额外训练专用网络，增加了模型准备和部署的负担。例如，例如，HiDDeN 通过联合训练编码网络和解码网络，实现秘密信息的嵌入与恢复[3]。SteganoGAN 则采用生成对抗网络，通过联合优化编码器、解码器和判别网络，提高图像隐写的信息容量和视觉质量[4]。这些方案虽然在信息隐藏方面取得了很好效果，但其需要专用网络的训练与部署工作。因此，如何充分复用现有资源，在减少额外模型准备成本的同时实现安全且隐蔽的信息传输，是一个关键问题。

深度神经网络（Deep Neural Network，DNN）已广泛应用于图像处理等领域，并逐渐成为各类信息系统的重要计算资源[5]。近年来，DNN 与密码学[6-7]，图像隐写[8]等领域的交叉研究，也表明 DNN 不仅能够用于传统的图像处理任务，还可以在信息安全领域发挥重要作用。从实现原理来看，视觉 DNN 能够通过非线性变换，将输入图像映射为高维神经元状态，适合表示含义丰富的信息[9]。同时，DNN 的神经元状态会随着输入图像的变化而变化，因此可以通过调整输入图像来控制神经元状态。我们受此启发，提出了一种基于表示的框架。该框架可以不修改现有 DNN 参数和原有功能，利用其内部神经元状态实现安全且隐蔽的信息表示。具体而言，我们将信息标识为选定神经元的目标状态，并通过对抗优化将随机图像迭代为外观自然的密文图像。当密文图像与预共享图像密钥结合时，可在 DNN 中诱导出目标状态，从而实现密钥控制的消息恢复。

然而，此类框架仍面临两个主要挑战，首先，如何准确稳定地诱导 DNN 产生目标神经元状态。现有视觉 DNN 主要面向图像分类等任务，其内部神经元由多层网络共同决定，难以直接控制。已有研究表明，通过对术后如图像施加细微的对抗扰动，可以改变 DNN 的输出结果[10-11]。但是由于不同神经元对输入扰动的敏感程度存在差

异[12-13]，部分神经元的相应可能随着输入变化发生明显干瘪，而另一些神经元的相应变化小，难以达到预设的目标值，我们称其为不响应神经元。当利用神经元表示消息时，不响应神经元可能导致部分消息比特无法正确编码，从而降低信息表示的准确性，并增加生成过程所需的迭代次数。其次，如何在诱导目标神经元状态的同时抑制密文图像的信息泄露。为了诱导 DNN 神经元至目标状态，需要通过对抗优化不断调整输入图像。但是图像修改可能导致密文图像与原始图像存在视觉差异，攻击者有可能通过图像分析发现异常，即直接视觉泄露[14]。并且由于 DNN 的结构和参数公开，攻击者可以将截获密文直接输入相同 DNN，分析其内部神经元状态异常变化，形成间接 DNN 状态泄露隐私泄露。总而言之，提高目标状态诱导的准确性与稳定性，消除整体视觉特征和内部 DNN 状态异常，是设计方案的两大主要困难。

1.2 相关工作

在神经网络与密码学的交叉研究中，已有工作主要探索利用神经网络学习信息保护机制或实现密码操作。Abadi 和 Andersen[6] 提出了对抗神经密码学，通过联合训练负责加密、解密和攻击的三个神经网络，使网络自主学习信息保护方法，但该过程需要专门训练模型。Gérault 等人[7] 研究了如何利用 DNN 实现密码操作，针对传统密码算法的离散计算与神经网络连续计算之间的差异，提出了基于 ReLU 的实现方法，并分析了其正确性与安全性。这些研究表明了神经网络在密码学领域的应用潜力，但与直接利用现有 DNN 进行隐蔽信息表示仍有所不同。

在图像隐写领域，已有研究主要关注信息隐藏容量、图像质量和鲁棒性等问题[2, 16-18]。HiDDeN[3] 通过联合训练编码网络和解码网络实现信息嵌入与恢复，SteganoGAN[4] 则利用生成对抗网络提高信息隐藏容量，但这些方法需要额外训练专用网络，增加了模型准备和部署成本。为减少对专用网络训练的依赖，Kishore 等人[19] 提出固定神经网络隐写，通过优化输入图像而不修改网络参数实现信息隐藏。Ghamizi 等人[20] 利用对抗扰动改变神经网络的分类结果，将秘密信息表示为目标类别。Luo 等人[8] 进一步在固定神经网络隐写中引入密钥控制，使消息恢复受到密钥约束，并优化隐写图像的视觉质量。

1.3 作品特色

通过分析现有方案的不足，我们设计了一种基于图像密钥控制 DNN 状态的安全隐蔽信息表示框架（Secure and Stealthy Information Representation，SSIR）。该方案不需要重新训练神经网络，基于图像密钥融合、分组编码和对抗优化实现，具有以

下特点。

(1) 新型信息表示方法。与直接将信息嵌入图像的方式不同，SSIR 将消息编码为 DNN 中选定神经元的目标状态。发送方通过对抗优化调整图像，使其与图像密钥结合后能够产生对应的神经元状态，接收方使用相同密钥和 DNN 恢复消息。同时，考虑到部分神经元对输入扰动不敏感，我们采用分组编码，对相邻神经元的响应取平滑平均，减少单个神经元不响应带来的影响。

(2) 可靠低泄露。在生成密文图像时，对抗扰动可能留下视觉痕迹，也可能使 DNN 的内部状态发生异常变化。针对这两种情况，我们分别设计了直接视觉泄漏损失和间接 DNN 状态泄漏损失，并将其加入图像优化过程，尽量减少攻击者在没有图像密钥时能够观察到的信息痕迹。我们在 ImageNet 数据集和真实图像上进行了测试。实验中，通过调整学习率，直接视觉泄漏指标最高降低 99.79%；加入间接泄漏损失后，神经元状态偏差平均降低 56.02%。对于 150 位消息，生成密文图像约需 300 ~ 500 ms，恢复消息约需 10 ms。

(3) 查询有界安全性分析。除实验测试外，我们还对方案进行了理论分析，包括图像密钥与 DNN 非线性响应的关系、分组编码后的恢复一致性、密文图像随机生成中的重复输出可能，以及同一图像在兼容密钥下的多语义解释。在此基础上，推导了查询有界的 IND-CPA 和 IND-CCA1 区分优势上界。其中，查询有界指攻击者请求生成或恢复的次数有限，IND-CPA 对应攻击者不能请求恢复时仍难以区分挑战密文，IND-CCA1 则进一步计入挑战前恢复查询带来的额外区分差距。分析表明，在满足相应分布条件并限制每密钥查询次数时，攻击者的区分优势不超过给定上界。该结论明确了安全成立的条件，并为实际部署中确定每密钥查询上限、实施访问限制和制定密钥更新策略提供依据。

(4) 模型兼容与参数指导。SSIR 无需修改 DNN 参数，也不需要额外训练专用模型。它可以直接复用现有 DNN 完成信息表示于回复，降低在既有 DNN 中集成的门槛。本文跨设备测试表明，只要生成段和恢复段统一数值处理规则，即可无误收发消息，为实际跨设备部署提供明确工程指导。分组编码用于缓解部分神经元造成的生成失败，实验表明分组 2 再可表示消息量与生成速度之间较为均衡。本文形成了可直接用于部署的分组大小、学习率和跨设备数值规则选择参考，使方案能够在不改动原有模型的前提下降低部署与调参成本，并按应用需求在成功率、图像质量和生成时延之间进行权衡。

1.4 应用前景分析

当前，敏感信息传输面临双重困境：传统加密技术虽然能够保护消息内容，但无法隐藏通信行为本身，密文在公开信道上的频繁出现容易引起第三方注意；图像隐写技术虽然能够把消息隐藏到自然载体中，却往往依赖专用网络训练或额外组件，部署成本较高。随着即时通信、物联网等场景的发展，会话密钥、控制指令等短小敏感信息需要在公开信道上频繁、快速、隐蔽地传递。SSIR 正是面向这一需求提出的，它利用图像密钥控制现有公开 DNN 的神经元状态，将消息编码为目标状态并生成外观自然的密文图像，接收方叠加密钥并输入 DNN 即可恢复。在具体实际部署中，SSIR 具有以下典型应用价值：

在即时通信场景中，传统的端到端加密虽然保护了聊天内容，但在建立会话时，密钥协商的报文特征往往非常明显，容易被流量审计设备识别并标记。SSIR 可以使得双方直接复用手机或个人电脑上现有的轻量级视觉模型，例如手机相册自带的分类模型，将新的会话密钥编码进一张普通的日常照片中，发送方只需像发送普通图片一样将密文图像发给对方，接收方叠加与共享的图像密钥即可瞬间恢复出新密钥。这样将密钥分发隐蔽成图一篇分享，大大降低密钥传递过程被检测的风险，且无需再终端额外部署庞大的加密网关或训练专用隐写模型。

在物联网场景中，设备间经常需要下发开启阀门、关闭传感器等短小控制指令。如果指令以明文或规定格式的密文传输，极易被监听者识别规律，甚至遭到针对性重放或阻断。由于边缘设备算力有限，无法运行复杂的隐写网络，SSIR 可以复用设备端已有的、用于图像质检或环境感知的 DNN 模型。下发端将指令编码为外观自然的密文图像，接收端直接从 DNN 神经元状态中读取指令。即使信道被持续监听，攻击者看到的也只是一组带有轻微自然噪点的图像流，难以区分哪一张包含了关键动作指令，从而提升了控制信道的抗干扰与抗流量分析能力。

在实际企业运行时，部署方可以根据自身对安全强度的要求，确定每个图像密钥允许的生成与恢复次数上限。系统后台对同一密钥的会话进行累计计数，当达到安全阈值前，自动触发密钥更新，各方独立生成并预共享新的替换密钥。系统会同时限制外部攻击者获取无限次的恢复响应。这一机制符合既定的密钥管理指南，避免了因单密钥过度使用而带来的安全风险，使系统在长期运行中保持了安全底线。

综上所述，SSIR 不仅是一种底层的信息表示方法，更具备显著的工程落地价值。它既能作为现有加密通信的增强曾，服务于企业内部的密钥管理或客户通信，也能在算力受限的物联网中，无需修改模型和额外训练，以极低的部署成本实现高可靠、低泄露的敏感信息传递。

第二章　作品设计与实现

2.1　系统方案

2.1.1　系统模型

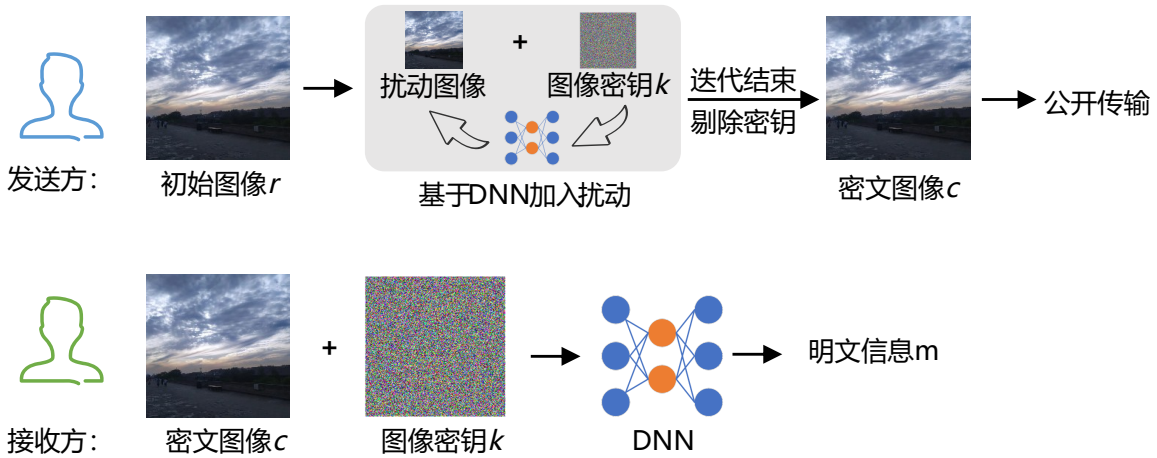


图 1: SSIR 系统模型

如图 1 所示，SSIR 面向由发送方与接收方构成的两方通信场景。与传统直接对明文施加密码变换的“先加密、后解密”范式不同，SSIR 将待传输的消息映射为公开深度神经网络（DNN）在特定输入下呈现的内部神经元状态，并利用公开传输的密文图像与双方秘密共享的图像密钥之间的像素级叠加关系，实现受密钥控制的信息表示与恢复。在部署条件上，通信双方仅需具备基础计算能力，并配备结构与参数完全一致的公开预训练图像分类模型（如 ResNet [21]、ShuffleNet V2 [24]），无需引入可信第三方或专用硬件支持。

从参与者的角度审视，SSIR 系统共涉及三**类参与者**：合法的发送方、合法的接收方，以及试图窃取信息的被动攻击者。三者的能力与目标分述如下。

发送方是消息的拥有者与通信的发起方。其能力包括：持有待传输的明文消息 m 与双方预先共享的图像密钥 k；配备与接收方结构、参数完全一致的公开预训练 DNN f_θ；掌握完整的分组编码规则（分组大小 g、判别阈值 t 等公开配置）；并具备执行基于梯度的迭代对抗优化（R-FGSM）所需的常规计算能力。发送方的目标是将明文消息 m 隐蔽且可靠地传递给接收方：既要使密文图像在叠加图像密钥后能够精确驱动出与消息对应的目标神经元状态，又要让密文图像在视觉上难以与自然图像区分，并同时抑制直接与间接两类信息泄漏。

接收方是合法通信的另一端，其能力与发送方高度对称但计算要求极低。接收方

持有与发送方相同的图像密钥 k、相同的预训练 DNN f_θ 及相同的编码规则，恢复过程仅需一次图像加法与一次前向推理，无需任何迭代优化。接收方的目标是从公开信道接收到的密文图像 c 出发，借助图像密钥无损且快速地还原出原始明文消息 m。

攻击者是被动窃听的第三方，其能力遵循 Kerckhoffs 原则设定。攻击者可完整截获公开信道上传输的密文图像 c，并掌握除图像密钥外的全部系统细节，包括模型结构与参数、编码规则、分组大小、判别阈值及优化超参数等，但不持有图像密钥 k。攻击者的目标有二：一是在无密钥条件下从截获的密文图像中恢复明文消息或推断图像密钥，二是将密文图像与自然图像区分开来，从而破坏系统的隐蔽性。

在实际通信前，收发双方通过安全信道预先共享一张图像密钥。当发送方需要传输明文消息时，首先将其编码为目标比特串，同时随机选取一张初始图像并与图像密钥逐像素叠加，构造出融合图像输入至 DNN 中，以观测选定神经元的激活响应。若当前神经元响应经编码后所得的比特串与目标比特串不符，发送方便利用 DNN 的梯度信息对扰动图像进行迭代微调，直至融合图像能够驱动 DNN 呈现出与明文消息完全对应的目标状态。微调收敛后，发送方从融合图像中减去图像密钥即可剥离出密文图像，并以无损格式经由公开信道发送。接收方作为合法通信实体，在收到密文图像后，只需将其与本地持有的同一图像密钥逐像素相加，即可还原出融合图像；随后将其输入同一 DNN 并读取相应神经元的响应，依据事先约定的分组编码规则即可直接解码出原始明文。由此可见，系统的计算开销主要集中在发送端的迭代优化阶段，而接收端的恢复过程仅包含一次图像加法与一次前向推理，无需任何迭代计算，因而具备极高的恢复效率。

在整个系统架构中，图像密钥是唯一需要保密的要素，而预训练 DNN 则作为公共计算资源被直接复用。图像密钥在形式上表现为与密文图像同尺寸的张量，其内容既可以是从特定分布中采样的随机噪声，也可以是任意自然图像，系统对其视觉语义不作限制。为消除跨平台计算误差，图像密钥、扰动图像、密文图像及模型输入均采用统一的固定精度张量格式进行存储与运算，以确保收发双方获得严格一致的数值结果。由于图像密钥通过逐像素加法参与融合图像的构造，且从未在公开信道中暴露，唯有持有正确密钥的接收方才能由密文图像还原出能够触发目标神经元状态的融合图像。与此同时，系统全程固定预训练 DNN 的公开参数，不对其进行重训练或微调，从而完整保留了模型原有的图像分类功能。正是因为深度神经网络具有高度非线性特征，同一图像密钥叠加在不同图像上所引起的神经元状态偏移与输入图像本身紧密耦合，从而奠定了图像密钥控制能力的安全基础；而网络自身的可微性质，则为发送端通过梯度反传开展对抗优化提供了计算支撑。

遵循 Kerckhoffs 原则，除上述图像密钥外，SSIR 所采用的模型结构与参数、编码规则、分组大小、二值化阈值以及优化超参数等配置均可完全公开。系统的安全性完全建立在图像密钥的保密性之上，攻击者即便掌握了完整的模型细节与编码机制，在缺乏图像密钥的情况下依然无法从公开截获的密文图像中提取出有效的明文信息。

2.1.2 设计目标与阶段划分

围绕上述通信模式，SSIR 在设计上致力于兼顾安全性、隐蔽性、运行效率与平台兼容性四方面要求。在安全层面，系统需保证未持有图像密钥的第三方无法恢复明文，在形式化意义下满足查询相关的选择明文安全（IND-CPA）与非自适应选择密文安全（IND-CCA1），能够有效抵御针对消息机密性与密钥保密性的各类分析攻击；在隐蔽层面，公开信道上传输的密文图像需尽可能抹除人为改动的痕迹，不仅要在视觉观感上与初始图像保持一致，还需确保攻击者在无密钥条件下将其直接输入 DNN 时，模型仅表现出与初始图像相近的常规状态；在效率与兼容性层面，系统应直接复用现有主流 DNN 架构而无需引入除图像密钥外的任何附加秘密，在完整保留宿主模型原有分类功能的前提下，支持紧凑型高价值消息的高效处理以及跨软硬件平台的稳定运行。

为实现上述目标，SSIR 的核心处理逻辑涵盖了消息编码、状态诱导、泄漏抑制优化以及消息恢复四个环节。顺应信息在系统中的流转次序，整体运行过程可划分为初始化、密文图像生成与消息恢复三个阶段。

在初始化阶段，通信双方完成密钥分发与公开参数的同步。双方运行密钥生成算法 $k \leftarrow \mathrm{KeyGen}()$ 秘密生成并共享图像密钥，同时协商选定所使用的预训练 DNN 及配套的分组编码规范。该编码规范具体界定了用于承载消息的神经元所在网络层、选定神经元的索引顺序、每组相邻神经元的数量（即分组大小 g），以及将连续神经元激活值量化为二值比特的判别阈值 $t \in (0, 1)$。

进入密文图像生成阶段后，发送方首先将待传明文 m 映射为目标比特串 S_t，并随机采样一张自然图像 r，经归一化与固定精度转换后作为初始扰动图像 p_0。在此基础上，发送方循环执行密钥叠加、前向推理、当前比特串编码、联合损失计算以及基于梯度的扰动更新操作。每完成一步更新，发送方便重新合成融合图像并检验当前解码所得比特串 S_c 是否与目标串 S_t 完全吻合；一旦两者一致即终止迭代，并从最终融合图像中减去图像密钥 k，输出密文图像 c。

在最后的消息恢复阶段，接收方将接收到的密文图像 c 与本地图像密钥 k 逐像素叠加，重构出融合图像 i 并送入 DNN 进行单次前向传播，读取目标神经元状态后

按既定分组规则完成阈值判别与逆映射，即可无损还原出明文消息 m。

2.2 实现原理

本节结合系统核心处理环节，详细阐述 SSIR 的底层数学模型与实现机理，文中所涉主要符号及其定义汇总于表 1。

表 1: 符号说明表

符号	含义
k	图像密钥
m	明文消息
S_t、S_c	目标比特串、当前比特串
f_θ	所复用的深度神经网络
$z(i)$	融合图像 i 在选定神经元上的连续状态向量
$L_s = (ls_1, \ldots, ls_d)$	状态向量，d 为选定神经元个数
g	分组大小（每组相邻神经元个数）
t	编码阈值，$t \in (0, 1)$
α、β	直接/间接泄漏损失的权重
lr	学习率（更新步长）
ξ	执行级随机状态
T_{trc}	截断操作
p_n、c	扰动图像、密文图像
i_n	融合图像
l_{be}、l_d、l_{id}	位错误损失、直接泄漏损失、间接泄漏损失

在分组编码环节，系统需建立连续神经元激活值与离散消息比特之间的映射关系。发送方首先利用双射编码函数将明文消息 m 转化为长度为 $\ell = |S_t|$ 的二进制目标比特串 $S_t = \mathrm{Et}(m)$。给定融合图像 i，DNN 在预设神经元集合上按既定顺序输出连续状态向量：

$$L_s = (ls_1, ls_2, \ldots, ls_d) = z(i), \tag{1}$$

其中 d 表示选定神经元的总数，ls_j 为第 j 个神经元的响应值。若直接以阈值 t 对单个神经元响应进行二值化，由于深度网络中常存在部分对输入微扰不够敏感的惰性神经元，其激活值在梯度优化中难以跨过预设阈值，极易造成个别比特编码失败并拖慢整体收敛。针对这一现象，SSIR 引入了分组编码机制：将相邻的 g 个神经元划分为一个编码组（满足 $g\ell \le d$），先求取组内神经元响应的算术平均值，再将该均值与阈值 t 进行比对，从而导出当前比特串 $S_c = \mathrm{Ec}(z(i); g, t)$。第 i 个比特 s_{c_i} $(1 \le i \le \ell)$

的判定方式可表示为：

$$s_{c_i} = \begin{cases} 1, & \overline{ls}_i \geq t, \\ 0, & \overline{ls}_i < t, \end{cases} \qquad \overline{ls}_i = \frac{1}{g} \sum_{q=1}^{g} ls_{(i-1)g+q} \tag{2}$$

这种组内均值池化策略有效降低了编码过程对单一神经元响应灵敏度的依赖。即便组内个别神经元响应迟钝，只要同组其余神经元在梯度引导下产生足够的补偿响应使组均值越过阈值，该比特位即可正确编码。该策略仅以单次表示容量由 d 缩减至 $\lfloor d/g \rfloor$ 为代价，显著提升了状态诱导的收敛率与稳定性。

在分组编码的基础上，状态诱导旨在通过梯度优化求解出一幅特定扰动图像，使其与图像密钥叠加后能够驱动 DNN 产生与 S_t 一致的内部响应。发送方将随机采样的初始图像 r 归一化为初始扰动图像 p_0，并在第 n 轮迭代中将其与图像密钥 k 逐像素叠加构造融合图像 i_n：

$$p_0 = \frac{r}{255}, \qquad i_n = p_n + k \tag{3}$$

将 i_n 输入网络并完成分组编码后，若当前比特串 S_c 与目标串 S_t 尚不一致，则通过计算各组响应均值与目标比特之间的均方误差来度量位错误损失：

$$l_{\text{be}}^{(n)} = \sum_{i=1}^{\ell} \left(\overline{ls}_i^{(n)} - s_{t_i} \right)^2 \tag{4}$$

由于 $l_{\text{be}}^{(n)}$ 关于输入扰动图连续可微，发送方可通过反向传播求取其关于 p_n 的梯度并迭代修正像素值。需要指出的是，连续型损失 $l_{\text{be}}^{(n)}$ 仅用于提供梯度下降的搜索方向，而迭代终止则严格以离散条件 $S_c = S_t$ 作为判据。当状态诱导收敛后，发送方从融合图像中剥离图像密钥即可获得最终的密文图像：

$$c = i_n - k = p_n \tag{5}$$

由此可见，公开传输的密文图像 c 本质上是经迭代优化后的扰动图像 p_n，其自身并不包含图像密钥 k 的成分，第三方仅凭观测 c 无法直接还原出能够触发目标神经元状态的融合图像。

然而，单纯追求状态诱导的达成可能会在扰动图像中留下异常痕迹：一方面，像素微调可能引起密文图像 p_n 与初始图像 p_0 之间的视觉失真，构成直接信息泄漏；另一方面，攻击者即便没有密钥，也可将截获的 p_n 直接送入公开 DNN 中，通过比对模型内部响应的异常波动来实施检测或分析，从而构成间接信息泄漏。为同步抑制上

述两类风险，SSIR 在优化目标中引入了双重泄漏约束。其中，直接信息泄漏损失利用预训练视觉特征提取网络 vgg 度量 p_n 与 p_0 在感知特征空间的偏离程度：

$$l_d^{(n)} = |\mathrm{vgg}(p_n) - \mathrm{vgg}(p_0)| \tag{6}$$

间接信息泄漏损失则用于约束无密钥条件下 p_n 与 p_0 在宿主模型 f_θ 选定特征表示层 R 上的响应差异：

$$l_{\mathrm{id}}^{(n)} = |R(f_\theta(p_n)) - R(f_\theta(p_0))| \tag{7}$$

此外，考虑到不同硬件设备（如不同架构的 GPU 与 CPU）在底层浮点数运算上存在微小舍入差异，处于阈值边界附近的神经元状态可能因跨设备推理而发生比特翻转。同时为了保证生成的密文图像符合标准无损图像格式要求，系统在每步梯度更新后均对扰动图像施加截断操作 T_{trc}，即先将像素值裁剪至 $[0,1]$ 区间，再按 8 位色深阶梯进行离散化量化并以 32 位浮点格式（float32）存储：

$$T_{\mathrm{trc}}(x) = \frac{\lfloor 255x \rfloor}{255}, \quad x \in [0,1] \tag{8}$$

此处截断与裁剪仅作用于扰动分量 p_n，而融合图像 $i_n = p_n + k$ 的合成则严格执行逐元素可交换加法，不对其进行额外的数值裁剪，从而避免引入非线性截断误差。综合位错误损失与两项泄漏约束，第 n 轮迭代的联合损失函数及扰动图像更新规则可表述为：

$$L^{(n)} = l_{\mathrm{be}}^{(n)} + \alpha l_d^{(n)} + \beta l_{\mathrm{id}}^{(n)} \tag{9}$$

$$p_{n+1} = T_{\mathrm{trc}}\left(\text{R-FGSM}\left(p_n, \nabla_{p_n} L^{(n)}, lr; \xi, n\right)\right) \tag{10}$$

式中，α 与 β 分别为两项泄漏损失的平衡权重，lr 为更新步长。系统采用随机化快速梯度符号法（R-FGSM）沿梯度符号方向执行带随机扰动的一步更新，其步长扰动行为由每次执行时独立采样的随机状态 ξ 控制。每次加密时独立选取的初始图像 r 与执行级随机状态 ξ 共同构成了系统的两级随机源，赋予密文生成过程概率化特征，以满足密码学语义安全要求。在联合优化过程中，$l_{\mathrm{be}}^{(n)}$ 驱动叠加密钥后的融合图像逼近目标编码状态，而 $l_d^{(n)}$ 与 $l_{\mathrm{id}}^{(n)}$ 则将无密钥下的密文图像锚定在初始图像附近。权衡系数 α、β 及步长 lr 均由发送方在本地自主设定，接收方在解码时无需获知上述超参数。

当密文图像 c 传输至接收端后，消息恢复过程作为生成的逆向映射即可直接展开。接收方将密文图像 c 与本地图像密钥 k 逐像素相加重构融合图像 i，经 DNN 前

向推理提取选定神经元状态后，依次执行分组阈值解码与双射逆变换 Et^{-1}：

$$i = c + k, \qquad S_t = \mathrm{Ec}(z(i); g, t), \qquad m = \mathrm{Et}^{-1}(S_t) \tag{11}$$

得益于逐像素加法的交换律以及收发双方统一的固定数值精度，接收端合成的融合图像 $i = c + k = p_n + k$ 与发送端终止迭代时的融合图像完全等同，因此在同一确定性 DNN 映射下必然产出一致的神经元状态，从而确保明文消息的精确恢复。

2.3 系统流程

在明确底层原理的基础上，图 2 展示了 SSIR 从参数协商到消息还原的完整运行生命周期。通信双方在初始化阶段完成图像密钥共享与编码配置同步后，即可持续开展保密通信：发送方在本地完成迭代式的密文图像生成，并将结果以无损图像格式投入公开信道；接收方获取图像后通过单次前向推理完成确定性解码。这种非对称的计算负载分配使得复杂的对抗优化完全由发送方承担，极大减轻了接收方的实时处理负担。

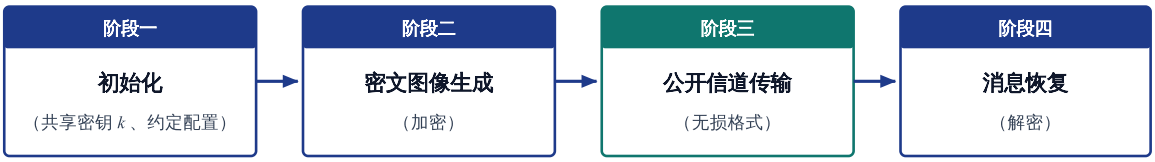


图 2: 系统生命周期

发送端生成密文图像的具体执行逻辑如图 3 与算法 1 所示。算法以随机初始图像 r、执行级随机状态 ξ、明文 m 及共享图像密钥 k 等作为输入。初始化完成后，发送方在 ‘while‘ 循环中持续检验当前融合图像 $p_n + k$ 所触发的编码比特串是否已收敛至目标串 S_t。只要两者存在偏差，算法便计算包含位错误损失、直接泄漏损失与间接泄漏损失的联合目标函数 $L^{(n)}$，并调用结合了固定精度截断算子 T_{trc} 的 R-FGSM 规则更新扰动图像 p_{n+1}。一旦某轮迭代后满足 $\mathrm{Ec}(z(p_n + k); g, t) = S_t$，循环立即终止，此时的扰动图像 p_n 即作为密文图像 c 输出。

相对应地，接收端的消息恢复流程如图 4 所示。接收方将密文图像与本地图像密钥逐像素叠加后送入 DNN，提取目标层选定神经元的激活状态，经分组均值计算与阈值二值化还原出目标比特串，最后通过逆编码映射恢复出明文消息。整个恢复链路均为确定性张量运算，不涉及任何随机采样或梯度迭代。

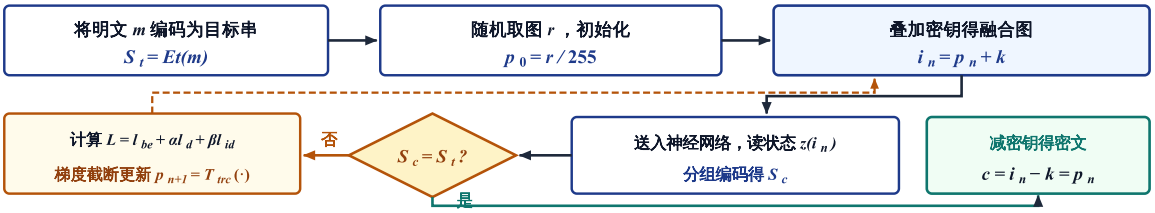


图 3: 密文图像生成流程

算法 1 密文图像生成

输入： 随机图像 r，随机状态 ξ，明文消息 m，图像密钥 k，DNN f_θ，状态读出 z，编码函数 Et、Ec，以及参数 g、t、α、β、lr、T_{trc}

输出： 密文图像 c

$p_0 \leftarrow r/255$，$S_t \leftarrow \text{Et}(m)$，$n \leftarrow 0$
while $\text{Ec}(z(p_n + k); g, t) \neq S_t$ **do**
  $i_n \leftarrow p_n + k$
  $L^{(n)} \leftarrow l_{\text{be}}^{(n)} + \alpha l_d^{(n)} + \beta l_{\text{id}}^{(n)}$
  $p_{n+1} \leftarrow T_{\text{trc}}\left(\text{R-FGSM}(p_n, \nabla_{p_n} L^{(n)}, lr; \xi, n)\right)$
  $n \leftarrow n + 1$
end while
$c \leftarrow p_n$
return c



图 4: 消息恢复流程

2.4 功能模块

依据上述系统架构与运行流程，SSIR 在软件实现上解耦为密钥与配置管理、编码、状态诱导、泄漏抑制以及密钥叠加与恢复五个核心功能模块，各模块间的调用与协作关系如图 5 所示。

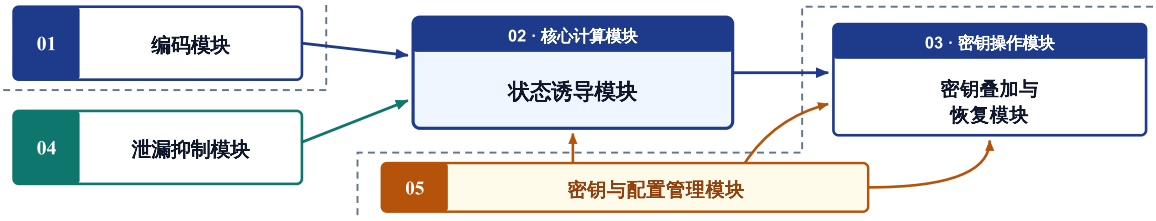


图 5: 系统功能模块

其中，**密钥与配置管理模块**承担系统底层的运行支撑职责，负责图像密钥的生成、安全预共享与定期更新策略，并维护收发双方在宿主 DNN 架构、目标神经元位置及分组参数等方面的配置同步，确保两端处于严格一致的运行环境。**编码模块**在明文语义空间与神经元状态空间之间提供双向转换接口：在发送端负责将明文转化为目标比特串，并将每次推理所得的选定神经元连续状态按分组均值规则量化为当前比特串；在接收端则依据完全对称的规则将神经元状态逆向解码为明文消息。

在发送端的核心优化链路中，**状态诱导模块**与**泄漏抑制模块**紧密协同。状态诱导模块主导对抗优化循环，利用反向传播获取的梯度信息持续调整扰动图像，直至叠加图像密钥后的融合图像能够准确触发目标神经元状态；泄漏抑制模块则在每步梯度计算中嵌入基于视觉特征的直接泄漏损失与基于模型内部表征的间接泄漏损失，同时在像素更新后执行固定精度截断操作，以确保生成的密文图像兼具视觉隐蔽性、表征隐蔽性与跨平台数值鲁棒性。而在接收端，**密钥叠加与恢复模块**负责将接收到的密文图像与本地图像密钥逐像素合成，并调用宿主模型与编码模块完成单次前向推理与消息还原。

2.5 性能指标

为定量刻画 SSIR 在恢复正确性、图像质量、信息泄漏与运行效率四个维度的表现，并与第 3 章实验测试的口径保持一致，本节统一给出各评价指标的定义。

恢复正确性指标。设目标比特串为 $S_t = \mathrm{Et}(m)$，接收方解码所得比特串为 $S_r = \mathrm{Ec}(z(c+k); g, t)$。比特错误率（Bit Error Rate，BER）定义为解码比特串与目标比

特串不一致的比特所占比例：

$$\mathrm{BER} = \frac{1}{\ell}\sum_{i=1}^{\ell} \mathbb{1}\big[s_{r_i} \neq s_{t_i}\big], \tag{12}$$

其中 $\mathbb{1}[\cdot]$ 为指示函数（条件成立取 1，否则取 0），$\ell = |S_t|$ 为消息比特长度，s_{t_i}、s_{r_i} 分别为目标与解码所得的第 i 个比特。BER 取值于 $[0,1]$，越低表示恢复越准确。完整消息恢复率（Exact Message Recovery，EMR）定义为测试样本中 BER 为零（整条消息逐比特完全一致）的样本所占比例：

$$\mathrm{EMR} = \frac{1}{M}\sum_{j=1}^{M} \mathbb{1}\big[\mathrm{BER}^{(j)} = 0\big], \tag{13}$$

其中 M 为测试消息总数。EMR 反映系统实现无损恢复的比例，越高越好。

图像质量指标。设初始图像 p_0 与密文图像 c 均为归一化至 $[0,1]$ 的 N 维像素向量。均方误差（Mean Squared Error，MSE）与峰值信噪比（Peak Signal-to-Noise Ratio，PSNR）分别定义为：

$$\mathrm{MSE}(p_0, c) = \frac{1}{N}\sum_{j=1}^{N}\big(p_0[j] - c[j]\big)^2, \qquad \mathrm{PSNR} = 10\log_{10}\frac{1}{\mathrm{MSE}(p_0,c)}, \tag{14}$$

PSNR 以分贝（dB）为单位，数值越大表示像素级差异越小。结构相似性（Structural Similarity，SSIM）从亮度、对比度与结构三个方面度量两幅图像的感知相似程度：

$$\mathrm{SSIM}(p_0, c) = \frac{\big(2\mu_0\mu_c + C_1\big)\big(2\sigma_{0c} + C_2\big)}{\big(\mu_0^2 + \mu_c^2 + C_1\big)\big(\sigma_0^2 + \sigma_c^2 + C_2\big)}, \tag{15}$$

其中 μ_0、μ_c 为局部均值，σ_0^2、σ_c^2 为局部方差，σ_{0c} 为局部协方差，C_1、C_2 为防止分母为零的稳定常数。SSIM 取值于 $[-1,1]$，越接近 1 表示结构越相似。此外，实验还以 L_1 与 L_2 距离刻画像素级差异：

$$\|p_0 - c\|_1 = \sum_{j=1}^{N}\big|p_0[j] - c[j]\big|, \qquad \|p_0 - c\|_2 = \Big(\sum_{j=1}^{N}\big(p_0[j] - c[j]\big)^2\Big)^{1/2}. \tag{16}$$

信息泄漏指标。直接信息泄漏刻画密文图像与初始图像在感知层面的可见差异。本作品沿用第 3 章的定义，将结构差异与均方误差的乘积作为直接泄漏代理指标：

$$\mathrm{Leak}_{\mathrm{dir}} = \big(1 - \mathrm{SSIM}(p_0, c)\big) \times \mathrm{MSE}(p_0, c), \tag{17}$$

该指标数值越小，表示可见差异越低，但不能等同于密码学意义上的区分优势。间接信息泄漏刻画无密钥条件下密文图像与初始图像在宿主模型内部表征上的差异，定义为二者在选定特征表示层 R 上的状态偏差：

$$\mathrm{Leak}_{\mathrm{ind}} = \big\| R(f_\theta(c)) - R(f_\theta(p_0)) \big\|, \tag{18}$$

该指标与发送端间接泄漏损失 l_{id} 同源，数值越小表示无密钥推理下的表征越接近自然图像，隐蔽性越强。

效率指标。生成成功率定义为在最大迭代次数 $T_{\max}$ 内达到 $S_c = S_t$ 的试验所占比例：

$$\mathrm{Succ} = \frac{N_{\mathrm{succ}}}{N_{\mathrm{trial}}}, \tag{19}$$

其中 N_{trial} 为总试验次数，N_{succ} 为成功收敛次数。迭代次数 n 为发送端状态诱导收敛时实际执行的 R-FGSM 更新步数；生成耗时 T_{gen} 与恢复耗时 T_{rec} 分别度量发送端生成单张密文图像与接收端恢复单条消息所需的平均时间。

综合实验测试与理论分析结果，SSIR 在安全性、隐蔽性、运行效率与架构兼容性四个方面均表现出良好的综合性能。在**安全性**方面，合法接收方在持有正确图像密钥时，消息恢复误码率稳定为 0%，精确恢复率达 100%；而在无密钥、随机伪造密钥或错误密钥条件下，攻击者解码所得比特串的误码率均维持在 50% 左右，退化为完全随机猜测。与此同时，形式化安全证明给出了系统在查询相关 IND-CPA 与 IND-CCA1 威胁模型下的优势上界，支持用户根据目标安全预算灵活设定单密钥允许的最大生成与恢复查询次数。

在**隐蔽性**方面，密文图像与初始自然图像在视觉上高度吻合，峰值信噪比（PSNR）最高可达 41.93 dB，结构相似性（SSIM）达到 97.99%；在泄漏抑制机制的作用下，直接信息泄漏指标低至 0.08，无密钥推理下的间接信息泄漏相较无约束基线平均降低了 56.02%。在**运行效率与兼容性**方面，系统无需任何前期的模型训练或额外参数存储，准备开销为零；针对 150 位长度的消息，发送端生成一张密文图像仅耗时约 300–500 ms，接收端完成消息恢复仅需约 10 ms。此外，依托固定精度截断机制，系统在跨设备（GPU 与 CPU 混合部署）场景下的恢复误码率同样保持为 0%，并且广泛兼容传统 CNN、Inception、Residual/Dense、Mobile/Efficient 以及注意力机制（Attention）等主流深度神经网络家族，在实现可靠信息传输的同时完整保留了宿主模型原有的业务功能。

第三章　作品测试与分析

本章围绕消息恢复、密钥控制、密文图像的视觉质量、跨设备一致性及生成效率，介绍本作品的测试方案、过程与结果。

3.1　测试方案

测试以一条消息的生成与恢复为基本流程：发送方选取初始图像和预共享图像密钥，将目标消息编码为神经元分组状态，经迭代优化得到密文图像；接收方使用相同密钥、DNN 和编码配置恢复消息。首先以正确密钥检查功能正确性，再更换随机密钥、其他样本的密钥或不提供密钥，观察恢复结果。为检验生成的随机性，在固定消息与密钥的条件下，分别改变初始图像及优化随机状态，或只改变优化随机状态，比较多次生成的图像。

测试还从四个方面考察作品性能。其一，比较不同分组大小下的生成成功率、迭代次数和用时，判断分组编码对不响应神经元的缓解作用。其二，以峰值信噪比（PSNR）、结构相似性（SSIM）、像素差异及直接泄漏代理指标评价图像质量，并比较启用和关闭间接泄漏损失时的神经元状态偏差。其三，测试截获样本分析、生成时间分析、跨设备恢复及图像失真后的恢复。其四，在相同消息长度和图像尺寸下比较生成、恢复及模型准备成本。消息恢复采用比特错误率（BER）和完整消息恢复率（EMR）：BER 越低越好，EMR 表示零比特错误消息所占比例。图像失真测试只报告 BER，不能据此推断每条消息均可完整恢复。

3.2　测试环境搭建

实验使用 ImageNet 数据集和实拍图像，图像尺寸包括 224×224 与 896×896。实验在 Ubuntu 系统上以 Python 3.10 和 PyTorch 运行，使用 RTX 4090 GPU。默认选取 ShuffleNet V2 的 softmax 前分类分数作为编码所用的 DNN 响应，利用随机化快速梯度符号方法（R-FGSM）生成密文图像。直接与间接泄漏损失的权重分别设为 $\alpha = 1000$ 和 $\beta = 100$，分组大小 $g = 2$，编码阈值为 0.5，学习率为 10^{-4}。除专门比较分组、学习率、模型或设备的实验外，其余测试沿用上述配置。

生成端和恢复端需要采用相同的模型、神经元选择、分组方式、阈值和数值处理规则，并预先秘密共享图像密钥。跨设备测试另外比较了启用与关闭截断处理 T_{trc} 的结果，以观察计算精度差异对消息恢复的影响。

3.3 测试设备

默认实验平台采用 RTX 4090 GPU。跨设备兼容性实验还使用 RTX 3070 GPU、Intel Core i7-13700K CPU 和 AMD Ryzen 9 5900HX CPU，并组合不同的生成端与恢复端。该实验用于检验同一消息和初始图像在不同计算设备之间传递时，数值精度变化是否造成解码错误。设备组合及结果见本章第 3.4 节。

3.4 测试功能

消息生成与密钥控制。本作品使用 100 组由不同图像密钥生成的消息与密文图像测试恢复功能。使用正确密钥时，BER 为 0%、EMR 为 100%；随机密钥、其他样本的错误密钥和无密钥时，BER 分别为 49.9%、49.7% 和 50.1%，EMR 均为 0%。因此，在这组测试中，只有正确密钥实现了完整恢复；错误或缺失密钥下的逐比特结果接近随机猜测。

概率生成。固定消息和图像密钥，分别独立采样初始图像及 R-FGSM 随机状态，完整生成 30 次；再固定初始图像，仅改变优化随机状态，生成 30 次。两组测试均未出现相同的固定精度输出。图 6 展示了第二组实验的代表性密文图像及其与原始图像的结构相似度，平均 SSIM 约为 97.5%。这说明在所测样本中，内部随机优化也能改变输出，同时保持较高的视觉相似度；有限次数的未碰撞观察不能给出任意运行次数下的碰撞概率。

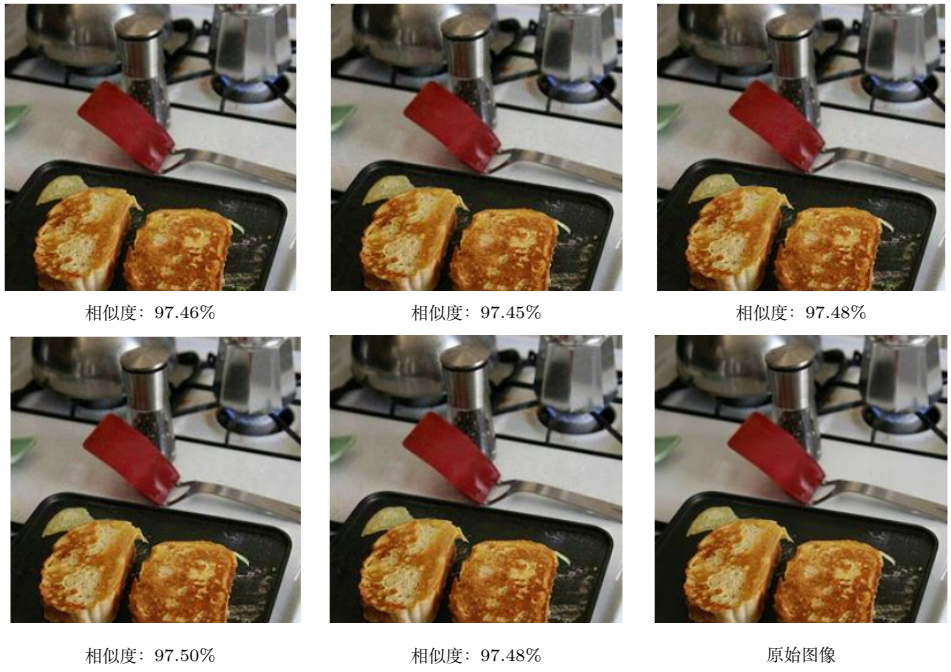


图 6: 固定初始图像时生成的密文图像与原始图像

图 6 中，五幅密文图像使用相同的初始图像、消息和图像密钥，仅改变优化过程的随机状态；右下角为原始图像。五幅密文图像的 SSIM 分别为 97.46%、97.45%、97.48%、97.50% 和 97.48%，数值集中在 97.5% 附近。从图中整体观察，物体轮廓、位置和主要颜色均与原图接近，说明这些生成结果在保持图像内容方面表现稳定；与此同时，五次输出并非同一幅固定精度图像。图示反映的是其中一次固定初始图像的代表性结果，多次生成是否重复仍应结合前述两组各 30 次的完整测试判断。SSIM 衡量视觉结构相似性，不能单独说明消息恢复是否正确，也不能作为密文安全性的证明。

分组编码。在 EfficientNet-B0 的 1280 维预分类特征上，以 150 位消息测试 $g \in \{1, 2, 4, 6\}$。每种设置进行了 2000 次配对试验，最大迭代次数为 3000。直接编码（$g = 1$）的成功率为 79%，$g = 2, 4, 6$ 均为 100%。其中 $g = 2$ 的成功样本平均迭代 47.5 次、生成耗时 317.8 ms；$g = 4$ 和 $g = 6$ 分别为 50.3 次、336.5 ms 及 59.1 次、389.7 ms。在这一配置下，$g = 2$ 同时保持较高表示容量和较低生成成本。

图像质量与泄漏抑制。以 L_1、L_2、SSIM 和 PSNR 衡量密文图像与原图的差异。本作品将 $(1 - \text{SSIM}) \times \text{MSE}$ 定义为直接视觉泄漏的代理指标；它衡量可见差异，不能等同于密码学区分优势。各方法的直接泄漏指标与图像质量见表 2。学习率分别为 10^{-3}、10^{-4}、10^{-5} 时，该指标为 39.34、0.41、0.08，对应 PSNR 为 26.62、38.14、41.93 dB，SSIM 为 72.24%、95.89%、97.99%。

表 2: 直接信息泄漏对比

方法	PSNR	SSIM	直接泄漏指标
FNNS [19]	33.01 dB	91.56%	2.74
SFNNS [8]	40.88 dB	97.92%	0.11
SteganoGAN-D [4]	38.40 dB	91.33%	0.81
SteganoGAN-B [4]	24.21 dB	81.67%	45.17
SSIR $(\mathrm{lr} = 10^{-3})$	26.62 dB	72.24%	39.34
SSIR $(\mathrm{lr} = 10^{-4})$	38.14 dB	95.89%	0.41
SSIR $(\mathrm{lr} = 10^{-5})$	41.93 dB	97.99%	0.08

表 2 将图像质量与直接泄漏代理指标并列，便于观察同一设置下视觉差异的变化。对本作品而言，学习率从 10^{-3} 降至 10^{-4} 时，PSNR 从 26.62 dB 升至 38.14 dB，SSIM 从 72.24% 升至 95.89%，直接泄漏指标由 39.34 降至 0.41；继续降至 10^{-5} 后，三项结果分别变为 41.93 dB、97.99% 和 0.08。因此，表中差异主要来自学习率的选择，不能只报出其中一行作为所有配置的图像质量。按本章采用的定义，直接泄漏指标同时包含结构差异与均方误差，数值越小表示该代理指标下的可见差异越低。

与表中其他方法相比，本作品在 $\mathrm{lr} = 10^{-3}$ 时的直接泄漏指标高于 FNNS、SFNNS 和 SteganoGAN-D；在 $\mathrm{lr} = 10^{-5}$ 时则低于这些列出的数值。这里比较的是表中的图像质量和代理指标，并未涵盖各方法的消息容量、恢复条件或模型准备成本，也不意味着数值较小就具有更强的密码学安全性。学习率降低带来的视觉质量改善还需与生成迭代及耗时一并权衡。

图 7 展示了不同学习率下密文图像 PSNR 与 SSIM 的互补累积分布。

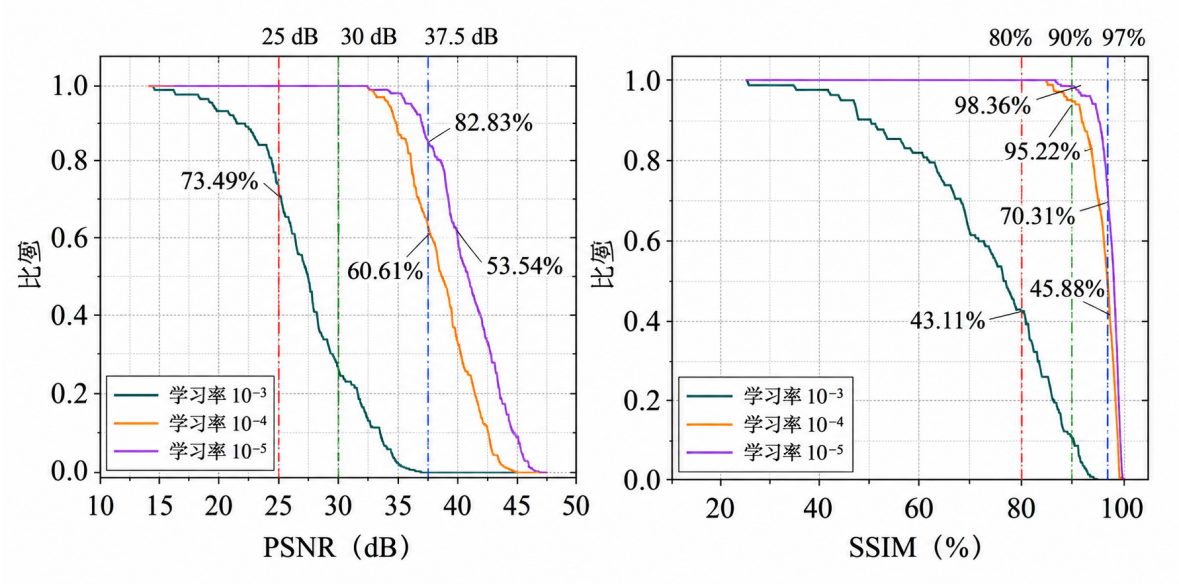


图 7: 不同学习率下密文图像 PSNR 与 SSIM 的互补累积分布

图 7 的纵轴表示达到或超过横轴阈值的密文图像比例，而不是单幅图像的 PSNR 或 SSIM。左图中，学习率为 10^{-3} 的 PSNR 曲线最先下降，10^{-4} 与 10^{-5} 的曲线依次向右移动；右图的 SSIM 曲线也呈现相同的整体次序。这意味着降低学习率后，获得较高 PSNR 和 SSIM 的图像在所测样本中占比提高。曲线还展示了各配置内部的分布：同一学习率下，不同样本并非都具有表 2 所列的平均质量，不能用一个平均值代替全部生成结果。

两幅图分别从像素误差和结构相似性观察图像质量，方向一致，但各自反映的差异并不完全相同。结合表 2，较小学习率在这组测试中同时对应更高的图像质量和更低的直接泄漏代理指标。图中的曲线只能说明这些评价量在已测图像上的分布，无法推断消息是否一定可恢复，也不能据此给出未测试图像或其他参数下的保证。

图 8 比较了 ResNet50、DenseNet121、EfficientNet V2 和 Inception V3 在启用与关闭间接泄漏损失时的神经元状态偏差。四个模型的平均降幅为 56.02%。

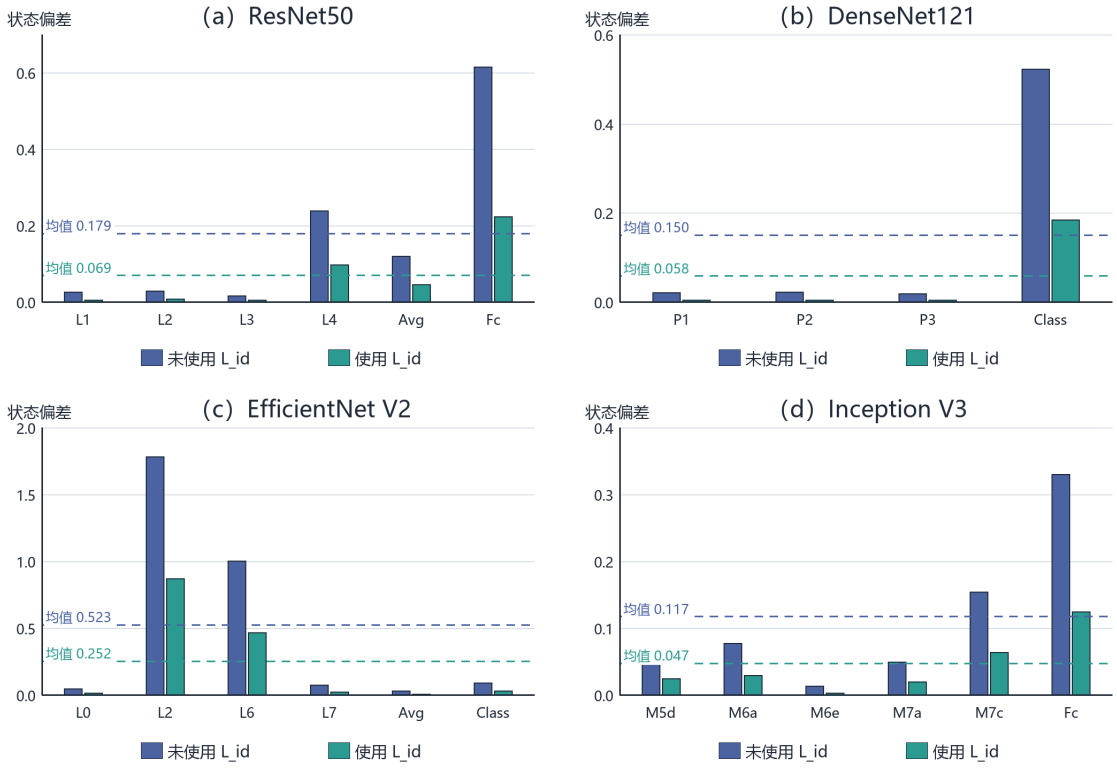


图 8: 四种网络的间接信息泄漏对比

图 8 按网络分别列出若干层及其总体状态偏差，蓝色表示未使用间接泄漏损失，青色表示使用该损失。启用损失后，四个网络所标出的平均状态偏差都下降：ResNet50 从 0.179 降至 0.069，DenseNet121 从 0.150 降至 0.058，EfficientNet V2 从 0.523 降至 0.252，Inception V3 从 0.117 降至 0.047。其中 EfficientNet V2 的原始偏差及下降后的偏差都高于其余三个网络，说明不同网络对这项约束的响应幅度并不相同。

从各层柱形看，较大的偏差集中在少数层或分类端，例如 ResNet50 的 Fc、DenseNet121 的 Class 以及 EfficientNet V2 的 L2 和 L6；加入损失后，这些位置的柱形均降低。因而，平均值的改善不是由所有层以相同幅度变化形成的，逐层观察有助于识别仍需关注的位置。这里的状态偏差用于评估间接泄漏抑制效果，不等同于从密文图像恢复消息的成功率；图示也只覆盖所列四种网络及其选取的层。

攻击、设备与传输扰动。截获消息–密文图像配对样本后训练恢复模型的实验中，随着样本数量增加，BER 仍约为 50%，未呈现稳定下降趋势。对高斯噪声图像密钥改变标准差并记录生成时间的实验，未观察到生成时间与密钥统计量之间的一致关系。这两项结论只适用于所测攻击方式和参数范围。跨设备测试中，启用截断处理后，RTX 4090、RTX 3070、i7-13700K 和 Ryzen 9 5900HX 的已测生成/恢复组合均达到

0% BER；未启用时，部分组合出现 0.67% 至 2.6% 的 BER。对密文图像施加高斯噪声、椒盐噪声、散斑噪声或 JPEG 压缩后，所测设置的 BER 为 0.03% 至 0.82%，表明其具有一定的比特级失真容忍度，但不能保证有损传输后的完整消息恢复。

3.5 结果分析

测试结果说明，SSIR 在上述配置下实现了由图像密钥控制的消息恢复。正确密钥测试达到零比特错误，而错误密钥和无密钥测试接近随机猜测。分组编码将所测成功率从直接编码的 79% 提高到 100%；继续增大分组未带来额外成功率收益，却降低了表示容量并增加生成时间。这支持选取 $g = 2$ 作为默认配置。两组各 30 次的随机生成测试也显示，初始图像和优化过程均可影响密文图像的具体形式。

视觉质量与速度之间存在可见取舍。学习率由 10^{-3} 降至 10^{-5} 时，直接泄漏代理指标从 39.34 降至 0.08，相对降幅为 99.79%；PSNR 与 SSIM 同时提高，但更小的学习率通常需要更多迭代。150 位消息、224×224 图像的效率比较中，SSIR 的密文图像生成耗时约 300–500 ms，恢复约 10 ms，且无需专用模型准备；对照方法的嵌入耗时为 50–120 ms，但模型准备需数小时。因而，SSIR 的在线生成速度并非最快，其优势主要体现在复用现有 DNN、避免专用模型准备，并同时满足所测配置下的密钥控制与视觉质量要求。

测试也给出适用边界。跨设备零 BER 依赖已测硬件组合及截断处理；失真测试虽显示较低 BER，仍会出现比特错误。直接泄漏数值是视觉差异的代理指标，截获样本和时间分析覆盖的是特定攻击条件。形式化的 IND-CPA 与 IND-CCA1 结论还依赖输出分布条件和每密钥查询限制，不能仅凭上述实验数值推出无条件安全性。相关形式化分析见下一节，具体证明见附录。

3.6 安全性分析

实验测试表明了方案在模拟攻击下表现良好，但密码方案的安全性需要严谨的数学推导作为支撑。为此，我们从三个层次递进展开：首先，分析了底层的 DNN 非线性响应机制，说明信息如何可靠嵌入并恢复。其次，刻画密文图像的概率生成过程与多语义特性，分析攻击者可能利用的随机性特征。最后，定义标准的 IND-CPA 与 IND-CCA1 密码学安全游戏，并在限制查询次数的前提下，推导攻击者成功区分密文的概率上界。本节中，ENC 表示算法 1 的完整生成流程（包括泄露损失与截断），DEC 表示消息恢复过程。

3.6.1 用于密钥控制表示的 DNN 非线性

本节主要阐明信息如何被可靠地嵌入 DNA 并准确提取。首先定义确定地映射函数 F_k, 然后划分融合图像区域，证明只要生成的图像落在特定区域内，就能通过阈值解码准确恢复消息，从而确立系统的恢复一致性。

1) 输入依赖的 DNN 响应： SSIR 使用选定神经元的分组响应来表示图像密钥下的消息。对于不同的密文图像，添加相同的密钥会在这些连续响应中产生不同的变化。因此，DNN 的非线性响应可以使密钥诱导的变化依赖于当前图像。附录 A 通过与操作域上的固定仿射映射进行比较，阐明了这种相互作用。

2) DNN 响应的离散使用： 受密码操作神经实现 [7] 的启发，SSIR 通过分组编码将连续 DNN 响应连接到离散消息状态。令 $\mathcal{M}$ 为支持的等长消息空间，具有双射编码 $\mathrm{Et}:\mathcal{M}\to\{0,1\}^{\ell}$，$C_{\mathrm{fp}}$ 为有限固定精度密文图像域，$\mathcal{K}=\mathrm{supp}(\mathrm{KeyGen})$ 为合法图像密钥域。我们考虑支持的配置，其中对于每个 $k\in\mathcal{K}$ 和 $m\in\mathcal{M}$，生成以正概率成功。定义

$$\begin{aligned} F_k(c) &= \mathrm{Ec}(z(c+k);g,t),\\ \mathrm{DEC}_k(c) &= \mathrm{Et}^{-1}(F_k(c)). \end{aligned} \tag{20}$$

在约定的 DNN、编码和数值设置下，双方评估相同的确定性映射 F_k。对于 $\mathcal{I}_{\mathrm{fp}}=C_{\mathrm{fp}}+\mathcal{K}$，将与字符串 s 相关联的融合图像区域定义为

$$\Omega_s=\{i\in\mathcal{I}_{\mathrm{fp}}:\mathrm{Ec}(z(i);g,t)=s\}. \tag{21}$$

那么当且仅当 $c+k\in\Omega_s$ 时，$F_k(c)=s$。在生成过程中，连续分组响应提供优化信号，而离散条件 $F_k(p_n)=\mathrm{Et}(m)$ 决定成功终止。因此，所得的 $c=p_n$ 满足 $\mathrm{DEC}_k(c)=m$。因此，相同的 DNN 响应指导状态诱导，并在阈值处理后确定恢复的字符串。当分组响应的变化超过配置的阈值时，它会影响所表示的比特。附录 B 详细介绍了这种从连续到离散的构造及其恢复一致性。

通过刻画输入依赖的非线性相应并构建分组阈值编码，我们证明了确定性映射下的恢复一致性。这意味着，在约定的 DNN、编码和数值精度下，只要通信双方使用正确的图像密钥，系统在数学上即能准确恢复原始消息，为后续分析密文图像的安全边界提供了正确性基础。

3.6.2 概率生成与多语义

SSIR 支持两种互补的表示形式：生成可以为固定消息和密钥产生不同的图像，而固定图像在兼容密钥下可以接受不同的消息解释。我们引入初始图像和优化状态双重随机源，推导生成结果的概率分布并计算出碰撞概率上界。同时，利用融合加法运算的可交换性质，构造出兼容密钥集合，证明单张图像可能对应多种合法解释。

1) 概率生成：每次生成尝试使用两个独立采样的随机源：

$$r \leftarrow D_R, \quad \xi \leftarrow D_\Xi, \quad c \leftarrow \mathrm{ENC}_k(m; r, \xi). \tag{13}$$

初始图像 r 确定 $p_0 = r/255$ 以及泄漏损失所使用的参考。执行级随机状态 ξ 确定随机化的 R-FGSM 更新。由于梯度从当前图像重新计算，这些随机化更新会影响后续的优化轨迹。

令 $p_{k,m}(c)$ 为成功生成条件下归一化的输出分布，且多次调用间具有独立的新随机性，令 $\mathcal{C} = \bigcup_{k,m} \mathrm{supp}(p_{k,m}) \subseteq C_{\mathrm{fp}}$。对于共享 k, m 的独立成功输出，

$$\Pr[c_1 = c_2 \mid k, m] = \sum_{c \in \mathcal{C}} p_{k,m}(c)^2 \le \varepsilon_{\mathrm{prob}}. \tag{14}$$

附录 C 通过区分具有相同和不同初始图像的执行来推导此一致界。它捕获了由两种随机源导致的输出离散度，并提供了下文使用的碰撞项。

2) 多语义：对于生成的图像 $c \in \mathcal{C}$ 和目标消息 $m \in \mathcal{M}$，定义兼容密钥集

$$\mathcal{K}(c, m) = \{k' \in \mathcal{K} : \mathrm{DEC}_{k'}(c) = m\}. \tag{15}$$

命题（多语义）。假设 $C_{\mathrm{fp}} \subseteq \mathcal{K}$。则对于每个 $c \in \mathcal{C}$ 和 $m \in \mathcal{M}$，$\mathcal{K}(c, m) \neq \emptyset$。

证明。由于 $c \in C_{\mathrm{fp}} \subseteq \mathcal{K}$，将 c 用作图像密钥，并选择一个成功输出 $c' \leftarrow \mathrm{ENC}_c(m)$。正确性给出 $F_c(c') = \mathrm{Et}(m)$。由于融合图像加法是可交换的，

$$F_{c'}(c) = F_c(c') = \mathrm{Et}(m). \tag{16}$$

由于 $c' \in C_{\mathrm{fp}} \subseteq \mathcal{K}$，$\mathrm{DEC}_{c'}(c) = m$，所以 $c' \in \mathcal{K}(c, m)$。□

这种构造为每个选定消息提供了对单张图像的替代解释。兼容密钥特定于所选的 (c, m) 对。下文的分析考虑了共享密钥的记录之间的依赖关系。

通过引入双重随机源并界定碰撞概率，结合融合映射的可交换性，我们证明了同一消息多次生成满足特定的碰撞上界，且单张图像存在多语义解释。这一结论说明，

攻击者既无法通过收集多次通信记录来寻找重复模式，也无法在截获单张密文图像后确定其唯一对应的明文，从而为抵抗统计分析和唯密文攻击提供了理论支撑。

3.6.3 形式化安全分析

DNN、编码规则和生成设置是公开的。实例化配置固定了 KeyGen、r 和 ξ 的分布、完整的生成过程以及数值设置。每个游戏采样一个 $k \leftarrow \mathrm{KeyGen}()$，并使用上述成功输出分布和新的生成随机性。查询计数在该密钥下跨消息和会话累计。对手是概率多项式时间算法，游戏涉及传输的图像和指定的预言机响应。

1) IND-CPA 优势界： 对手 $\mathcal{A}$ 在挑战前后自适应地查询 ENC_k。它提交等长消息 m_0, m_1，对于均匀的 $b \in \{0,1\}$，接收 $c^* \leftarrow \mathrm{ENC}_k(m_b)$，并输出 b'。其优势为 $\mathrm{Adv}_{\mathcal{A}}^{\mathrm{IND-CPA}} = |\Pr[b' = b] - 1/2|$。令 q 统计所有生成输出，包括 c^*。

我们将真实游戏与参考游戏进行比较，参考游戏为独立采样的均匀消息生成每个输出。令 η_q 为在最多 q 个输出且具有正参考似然的碰撞自由记录上，其转录似然比偏离 1 的最大绝对偏差。它衡量了这些记录中剩余的消息依赖性；附录 D 给出了其显式定义。

定理 1（查询有界 IND-CPA 优势）。每个接收最多 q 个输出的此类对手满足

$$\mathrm{Adv}_{\mathcal{A}}^{\mathrm{IND-CPA}} \leq \frac{\eta_q}{2} + \binom{q}{2}\varepsilon_{\mathrm{prob}}. \tag{17}$$

混合证明利用正确性将真实生成表示为来自参考分布的条件采样。碰撞自由记录对统计距离的贡献至多为 $\eta_q/2$，而重复输出对统计距离的贡献至多为 $\binom{q}{2}\varepsilon_{\mathrm{prob}}$。参考游戏不泄露关于 b 的任何信息。

对于优势预算 $\varepsilon_{\mathrm{sec}} = \varepsilon_{\mathrm{mix}} + \varepsilon_{\mathrm{col}} < 1/2$，附录 D 规定了关于 η_Q 和 $\varepsilon_{\mathrm{prob}}$ 的条件，以确定可接受的上限 $Q \geq 1$。对于满足这些条件的任何上限，

$$\mathrm{Adv}_{\mathcal{A}}^{\mathrm{IND-CPA}} \leq \varepsilon_{\mathrm{sec}}, \quad 1 \leq q \leq Q. \tag{18}$$

这给出了 CCA1 分析的仅生成基线。可接受的上限取决于实例化分布和所选择的优势预算。

2) IND-CCA1 优势界： 对手 $\mathcal{A}'$ 可以在挑战前自适应地查询 ENC_k 和 DEC_k，但挑战后只能查询 ENC_k。挑战消息与优势定义沿用上述 IND-CPA 游戏。保留 q 作为生成输出的数量，并令 q_d 统计挑战前的恢复查询 $x \in C_{\mathrm{fp}}$。

为了分离恢复访问的影响，比较同密钥和分裂密钥预言机游戏。两者都使用 k 进

行生成；分裂密钥游戏在一个独立的固定密钥 $\bar{k}$ 下回答首次非重放恢复查询，同时保留缓存和精确重放响应。令 $\delta_{\mathrm{dec}}(q, q_d)$ 为这些限制下它们的最大区分概率差距；见附录 E。

定理 2（查询有界 IND-CCA1 优势）。对于每个这样的 $\mathcal{A}'$，存在一个 IND-CPA 对手 $\mathcal{A}$ 使得

$$\begin{aligned} \mathrm{Adv}_{\mathcal{A}'}^{\mathrm{IND-CCA1}} &\leq \mathrm{Adv}_{\mathcal{A}}^{\mathrm{IND-CPA}} + \delta_{\mathrm{dec}}(q, q_d) \\ &\leq \frac{\eta_q}{2} + \binom{q}{2}\varepsilon_{\mathrm{prob}} + \delta_{\mathrm{dec}}(q, q_d). \end{aligned} \tag{19}$$

分裂密钥视图可以使用 CPA 预言机和 k 下的本地恢复来模拟。附录 E 通过密钥解耦行为以及较早的恢复输入后来作为生成输出出现的概率，来界定额外的差距。给定一个可接受的 Q，它指定了恢复查询限制 $q_d \geq 0$ 的条件，使得

$$\mathrm{Adv}_{\mathcal{A}'}^{\mathrm{IND-CCA1}} \leq \varepsilon_{\mathrm{sec}} + \varepsilon_{\mathrm{dec}}, \quad 1 \leq q \leq Q, \quad q_d \leq Q_d, \tag{20}$$

其中 $\varepsilon_{\mathrm{sec}} + \varepsilon_{\mathrm{dec}} < 1/2$。当 $q_d = 0$ 时，额外差距消失，结果退化为定理 1。

这些条件规定了允许的每密钥使用量：部署可以强制执行不大于可接受 (Q, Q_d) 的生成和恢复上限，同时保持所分析的预言机访问模式。有用限制的存在性和大小取决于实例化分布。在部署中还应通过密钥更新和访问限制控制累计查询。

我们严格推导出了查询有界的 IND-CPA 与 IND-CCA1 优势上界，并确定了安全成立的条件。这意味着，在满足相关输出分布条件，且遵守给定的每密钥生成查询上限 (Q) 与恢复查询上限 (Q_d) 时，攻击者的区分优势被严格限制在预定的安全预算之内。该结论表明系统可以通过限制访问频次和定期更新密钥，来确保在长期运行中始终维持给定的安全性标准。

第四章　创新性说明

4.1　原理创新

本作品针对传统加密与图像隐写直接结合需要额外组件、神经密码学依赖专门网络训练等问题，提出了 SSIR——一种由图像密钥控制现有公开 DNN 状态的安全隐蔽信息表示框架。与已有方案不同，SSIR 不将消息嵌入像素或专用网络，而是将消息表示为目标 DNN 神经元状态。具体而言，发送方将随机图像与预共享图像密钥融合，输入公开 DNN；通过分组编码将消息编码为目标比特串，并利用分组神经元响应与目标比特之间的可微损失，指导对融合图像的对抗优化，直至 DNN 呈现目标状态；随后减去图像密钥得到密文图像。接收方将密文图像与图像密钥叠加，输入同一 DNN，通过解码神经状态恢复消息。该原理将密钥控制的消息恢复与隐蔽的公共传输统一起来，密文图像保持自然外观，非线性响应和概率生成支持输入依赖的密钥控制以及多样的公共表示。为缓解不响应神经元的影响，本作品设计分组编码，对相邻神经元响应取平均，提高状态诱导可靠性。此外，本作品识别并抑制两类泄漏：直接视觉泄漏和间接 DNN 状态泄漏，通过基于损失的联合优化同时降低二者。形式化分析方面，本作品推导了查询有界的 IND-CPA 和 IND-CCA1 优势界，给出了有界查询安全的分布条件和每密钥查询限制。

4.2　性能创新

本作品在性能上的创新主要体现在对现有 DNN 基础设施的直接重用和高效生成恢复。首先，SSIR 无需专门的模型训练，也无需修改所复用 DNN 的参数，原有推理功能得以完整保留，从而显著降低引入专用安全模型的准备与整合开销。公共 DNN 与编码配置相互独立，为构建独立控制的实现提供了灵活性。其次，本作品通过分组编码和基于损失的优化，在保证可靠性的同时提升生成效率。实验表明，生成一条 150 位信息的密文图像仅需 300 ms，消息恢复仅需 10 ms，且无需额外模型准备。SSIR 兼容多种常见 DNN，并在图像失真条件下容忍比特级误差，对多种攻击具有鲁棒性。模块化设计使生成与恢复过程可独立优化，便于在不同部署环境中按需配置。

4.3　安全与部署创新

在安全性方面，本作品不仅依赖经验评估，还进行了形式化安全分析。SSIR 利用高维图像密钥提供灵活的内容表示和大的候选域；当 KeyGen 提供足够的最小熵

时，穷举密钥搜索在计算上不可行。密钥与传输图像及公共 DNN 配置保持分离，增强了密钥控制的独立性。形式化分析给出了查询有界的 IND-CPA 和 IND-CCA1 优势界，并规定了有界查询安全所需的分布条件和每密钥查询限制。这些结论为部署方配置密钥使用与更新策略提供了依据：在允许范围内为每个密钥选择生成和恢复上限，以满足目标优势预算；计数应在共享同一密钥的会话中累计；在进一步使用可能超过上限之前，各方独立生成并秘密预共享替换密钥，同时将外部恢复访问限制在已分析的威胁模型内。上述措施符合既定密钥管理指南[26]，使系统在长期运行中保持可配置的安全边界。在应用部署上，SSIR 可用于会话密钥的传递或刷新、机密信号通信、秘密投递通信，以及物联网、应急通信等需要兼顾安全性与隐蔽性的场景，具有较好的实用前景。

第五章　总结

本作品针对传统加密技术难以隐藏通信行为、部分深度学习图像隐写方案需要额外训练专用网络等问题，设计并实现了基于图像密钥控制 DNN 状态的安全隐蔽信息表示框架 SSIR。该框架直接利用现有 DNN 的内部神经元状态表示消息，通过图像密钥和对抗优化实现信息的生成与恢复，无需修改模型参数或原有功能。主要完成了以下四个方面的工作：

1. 提出了基于 DNN 状态的信息表示方法。将消息编码为选定神经元的目标状态，通过图像密钥融合与对抗优化生成密文图像，接收方利用相同密钥和 DNN 恢复原始消息。

2. 设计了分组编码机制。针对部分神经元对输入扰动不敏感的问题，通过对相邻神经元响应取平均，减少单个神经元不响应的影响，提高目标状态诱导的可靠性。

3. 设计了双重信息泄漏抑制方法。针对密文图像可能存在的直接视觉泄漏和间接 DNN 状态泄漏，设计联合损失函数，在生成过程中同时减少视觉变化和神经元状态偏差。

4. 进行了形式化安全分析。分析了密文图像的概率生成与多语义特性，推导了查询有界的 IND-CPA 和 IND-CCA1 区分优势上界，并给出了查询有界安全性所需的分布条件和单密钥查询次数限制。

本作品在 ImageNet 数据集和真实图像上进行了实验测试。结果表明，分组编码将所测生成成功率由 79% 提高至 100%；通过调整优化参数，直接视觉泄漏指标最高降低 99.79%，启用间接泄漏约束后，神经元状态偏差平均降低 56.02%。对于 150 位消息，密文图像生成时间约为 300 ~ 500 ms，消息恢复时间约为 10 ms。SSIR 还能够适配多种常见 DNN，并在测试条件下表现出一定的攻击鲁棒性和图像失真容忍能力。

综上，SSIR 在不额外训练专用网络的情况下，实现了由图像密钥控制的信息表示与恢复，并通过分组编码和泄漏抑制机制提高了方案的可靠性与隐蔽性。该方案可用于进一步探索会话密钥传递、物联网控制指令和企业内部短消息等信息的隐蔽传输，但实际部署时仍需考虑密钥共享、查询次数限制和密钥更新等问题。

参考文献

[1] Y. Wang and P. Moulin, "Perfectly secure steganography: Capacity, error exponents, and code constructions," *IEEE Transactions on Information Theory*, vol. 54, no. 6, pp. 2706–2722, 2008.

[2] Z. Yang, K. Chen, K. Zeng, W. Zhang, and N. Yu, "Provably secure robust image steganography," *IEEE Transactions on Multimedia*, vol. 26, pp. 5040–5053, 2024.

[3] J. Zhu, R. Kaplan, J. Johnson, and L. Fei-Fei, "Hidden: Hiding data with deep networks," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 657–672.

[4] K. A. Zhang, A. Cuesta-Infante, L. Xu, and K. Veeramachaneni, "Steganogan: High capacity image steganography with gans," *arXiv preprint arXiv:1901.03892*, 2019.

[5] Y. LeCun, Y. Bengio, and G. Hinton, "Deep learning," *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.

[6] M. Abadi and D. G. Andersen, "Learning to protect communications with adversarial neural cryptography," *arXiv preprint arXiv:1610.06918*, 2016.

[7] D. Gerault, A. Hambitzer, E. Ronen, and A. Shamir, "Deep neural cryptography," in *Advances in Cryptology – EUROCRYPT 2026*, ser. Lecture Notes in Computer Science, vol. 16546. Springer, 2026, pp. 513–543.

[8] Z. Luo, S. Li, G. Li, Z. Qian, and X. Zhang, "Securing fixed neural network steganography," in *Proceedings of the 31st ACM International Conference on Multimedia (MM)*, 2023, pp. 7943–7951.

[9] Y. Bengio, A. Courville, and P. Vincent, "Representation learning: A review and new perspectives," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 35, no. 8, pp. 1798–1828, 2013.

[10] C. Szegedy, W. Zaremba, I. Sutskever, J. Bruna, D. Erhan, I. Goodfellow, and R. Fergus, "Intriguing properties of neural networks," in *International Conference on Learning Representations*, 2014.

[11] I. J. Goodfellow, J. Shlens, and C. Szegedy, "Explaining and harnessing adversarial examples," in *International Conference on Learning Representations*, 2015.

[12] C. Zhang, A. Liu, X. Liu, Y. Xu, H. Yu, Y. Ma, and T. Li, "Interpreting and improving adversarial robustness of deep neural networks with neuron sensitivity," *arXiv preprint arXiv:1909.06978*, 2019.

[13] A. Suri and D. Evans, "One neuron to fool them all," *arXiv preprint arXiv:2003.09372*, 2020.

[14] K. Hu, M. Wang, X. Ma, J. Chen, X. Wang, and X. Wang, "Learning-based image steganography and watermarking: A survey," *Expert Systems with Applications*, p. 123715, 2024.

[15] J. Deng, W. Dong, R. Socher, L.-J. Li, K. Li, and L. Fei-Fei, "Imagenet: A large-scale hierarchical image database," in *2009 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2009, pp. 248–255.

[16] Y. Yao, L. Huang, H. Wang, Q. Chang, W. Ren, and F. Xiao, "Robust adaptive steganography based on adaptive STC-ECC," *IEEE Transactions on Multimedia*, vol. 26, pp. 5477–5489, 2024.

[17] F. Li, H. Liu, X. Zhang, and C. Qin, "StegFlow: Flow-based high-frequency distribution mapping network for multi-image steganography," *IEEE Transactions on Multimedia*, vol. 27, pp. 9555–9569, 2025.

[18] X. Liu, L. Zhong, X. Kang, G. Schaefer, D. Huang, and Z. Ma, "High-capacity generative image steganography approach for hiding multiple secret images," *IEEE Transactions on Multimedia*, vol. 28, pp. 4942–4955, 2026.

[19] V. Kishore, X. Chen, Y. Wang, B. Li, and K. Q. Weinberger, "Fixed neural network steganography: Train the images, not the network," in *International Conference on Learning Representations (ICLR)*, 2021.

[20] S. Ghamizi, M. Cordy, M. Papadakis, and Y. Le Traon, "Evasion attack Steganography: Turning vulnerability of machine learning to adversarial attacks into a real-world application," in *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV) Workshops*, October 2021, pp. 31–40.

[21] K. He, X. Zhang, S. Ren, and J. Sun, "Deep residual learning for image recognition," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, pp. 770–778.

[22] N. Döttling, J. Müller-Quade, and A. C. A. Nascimento, "Ind-cca secure cryptography based on a variant of the lpn problem," in *International Conference on the Theory and Application of Cryptology and Information Security (ASIACRYPT)*, 2012, pp. 485–503.

[23] F. Günther, D. Stebila, and S. Veitch, "Obfuscated key exchange," in *Proceedings of the 2024 on ACM SIGSAC Conference on Computer and Communications Security (CCS)*, 2024, pp. 2385–2399.

[24] N. Ma, X. Zhang, H.-T. Zheng, and J. Sun, "Shufflenet v2: Practical guidelines for efficient cnn architecture design," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2018, pp. 116–131.

[25] GitHub Repository, "SSIR: A secure and stealthy information representation framework via image-key-controlled dnn states," 2025, accessed: Nov. 14, 2025. [Online]. Available: `https://github.com/no-nameno-name/SSIR`.

[26] E. Barker, "Recommendation for key management: Part 1—general," National Institute of Standards and Technology, Tech. Rep. NIST SP 800-57 Part 1 Rev. 5, May 2020. [Online]. Available: `https://doi.org/10.6028/NIST.SP.800-57pt1r5`.

附录

附录 A　操作域上的非线性

DNN 组件产生输入依赖的局部响应，这些响应跨特征混合并跨层复合。对于具有 L 个隐藏层和逐点激活的前馈网络，在可微点处的雅可比矩阵具有如下形式

$$J_{f_\theta}(x) = W^{(L+1)} D^{(L)}(x) W^{(L)} \cdots D^{(1)}(x) W^{(1)}, \tag{21}$$

其中 $W^{(l)}$ 是权重矩阵，$D^{(l)}(x)$ 包含在当前预激活处的激活导数。对于 ReLU 网络，局部仿射映射可以跨越激活区域发生变化，其数量取决于架构[10]。

令 $G(i) = (\overline{l_{s_1}(i)}, \ldots, \overline{l_{s_\ell}(i)})$ 表示选定神经元的分组响应。如果单个仿射映射在包含被比较输入的定义域上描述 G，那么

$$G(i) = Ai + b \quad \Longrightarrow \quad G(c+k) - G(c) = Ak. \tag{22}$$

此时连续响应中由密钥诱导的变化独立于 c。非线性映射可以使这一变化依赖于 c，从而塑造图像与密钥之间的相互作用。附录 B 中的阈值决策确定了这些响应如何转换为离散消息状态。

这一比较解释了 SSIR 所使用的响应机制。附录 D 和 E 中的安全界刻画了所得的输出分布和恢复分布。

附录 B　连续到离散状态表示

令 $z(i) \in \mathbb{R}^d$ 为第 IV-C1 节中定义的选定神经元状态向量，其中 $g\ell \le d$ 且 $t \in (0,1)$。定义

$$G_j(i) = \frac{1}{g} \sum_{a=g(j-1)+1}^{gj} z_a(i), \tag{22}$$

$$[F_k(c)]_j = \mathbf{1}[G_j(c+k) \ge t], \quad 1 \le j \le \ell. \tag{23}$$

对于每个 $s \in \{0,1\}^\ell$，关联的阈值单元为

$$\mathcal{B}_s = \{u \in \mathbb{R}^\ell : \mathbf{1}[u_j \ge t] = s_j \text{ for all } j\}. \tag{24}$$

单元 $\mathcal{B}_s$ 划分 $\mathbb{R}^\ell$，并且

$$\Omega_s = G^{-1}(\mathcal{B}_s) \cap \mathcal{I}_{\mathrm{fp}}. \tag{25}$$

因此，非空的 Ω_s 划分了融合图像域，并且每个输入恰好确定一个表示字符串。

在生成过程中，连续损失

$$l_{be}^{(n)} = \sum_{j=1}^{\ell} (G_j(p_n + k) - s_{t_j})^2 \tag{26}$$

与直接和间接泄漏损失一起指导优化。截断产生下一个固定精度图像，其离散状态由算法 1 中的循环条件评估。因此，成功终止由下式确定

$$F_k(p_n) = S_t \iff p_n + k \in \Omega_{S_t}. \tag{27}$$

约定的数值约定固定了图像表示、融合加法、DNN 推理、状态读出、分组和阈值评估。融合使用可交换的逐元素加法，无截断或溢出；T_{trc} 中的截断应用于更新后的图像分量。双方评估相同的确定性 F_k。对于成功输出 $c = p_{n^*}$，恢复因此给出

$$\widehat{S}_t = F_k(c) = S_t, \quad \mathrm{DEC}_k(c) = \mathrm{Et}^{-1}(S_t) = m. \tag{28}$$

这是下文使用的正确性关系。截断使优化和恢复期间使用的图像表示一致，而约定的评估约定确定状态映射。

附录 C　概率密文图像生成的进一步分析

A. 成功输出分布

令 $\mathcal{R} = \mathrm{supp}(D_R)$ 且 $\Xi = \mathrm{supp}(D_\Xi)$，并令 Succ 表示成功终止。每次尝试独立采样 r 和 ξ。对于固定的 k, m，成功执行中初始图像的分布为

$$w_{k,m}(r) = \frac{D_R(r)\,\Pr[\mathrm{Succ} \mid k, m, r]}{\Pr[\mathrm{Succ} \mid k, m]}. \tag{29}$$

由第 V 节中的支持配置条件，分母为正。令 $\mathcal{R}_{k,m} = \mathrm{supp}(w_{k,m})$。对于 $r \in \mathcal{R}_{k,m}$，定义

$$\begin{aligned} p_{k,m,r}(c) &= \Pr[\mathrm{ENC}_k(m; r, \xi) = c \mid \mathrm{Succ}, k, m, r], \\ p_{k,m}(c) &= \sum_{r \in \mathcal{R}_{k,m}} w_{k,m}(r)\, p_{k,m,r}(c), \end{aligned} \tag{30}$$

其中第一个概率是对 $\xi \leftarrow D_\Xi$ 取的。这些分布是归一化的，并且成功输出预言机的独立调用独立地采样 $p_{k,m}$。

B. 碰撞贡献与一致界

定义来自不同初始图像的输出分布之间的最大重叠为

$$\varepsilon_{\text{init}} = \max_{\substack{k\in\mathcal{K},\ m\in\mathcal{M}\\ r_1,r_2\in\mathcal{R}_{k,m},\ r_1\neq r_2}} \sum_{c\in\mathcal{C}} p_{k,m,r_1}(c)p_{k,m,r_2}(c). \tag{31}$$

如果不存在可接受的相异对，则令 $\varepsilon_{\text{init}} = 0$。对于固定初始图像，定义

$$\varepsilon_{\text{opt}} = \max_{\substack{k\in\mathcal{K},\ m\in\mathcal{M}\\ r\in\mathcal{R}_{k,m}}} \sum_{c\in\mathcal{C}} p_{k,m,r}(c)^2. \tag{32}$$

这两个量分别界定了不同初始图像之间和固定初始图像内部的碰撞。

对于固定的 k, m，简记 $w_r = w_{k,m}(r)$ 和 $p_r = p_{k,m,r}$，并令 $\kappa_{k,m} = \sum_r w_r^2$。两个独立的成功输出满足

$$\begin{aligned}\Pr[c_1 = c_2 \mid k, m] &= \sum_r w_r^2 \sum_c p_r(c)^2 \\ &\quad + \sum_{r_1\neq r_2} w_{r_1} w_{r_2} \sum_c p_{r_1}(c)p_{r_2}(c) \\ &\leq \kappa_{k,m}\varepsilon_{\text{opt}} + (1-\kappa_{k,m})\varepsilon_{\text{init}}.\end{aligned} \tag{33}$$

因此，

$$\varepsilon_{\text{prob}} = \max_{k,m} \left[(1-\kappa_{k,m})\varepsilon_{\text{init}} + \kappa_{k,m}\varepsilon_{\text{opt}}\right] \tag{34}$$

是式 (14) 的一致界，并且 $\Pr[c_1 \neq c_2 \mid k, m] \geq 1 - \varepsilon_{\text{prob}}$。

如果每次尝试都以概率 1 成功，则 $w_{k,m} = D_R$ 且 $\kappa_{k,m} = \kappa_R = \sum_r D_R(r)^2$，于是

$$\varepsilon_{\text{prob}} = (1-\kappa_R)\varepsilon_{\text{init}} + \kappa_R\varepsilon_{\text{opt}}. \tag{35}$$

泄漏损失倾向于使图像与初始图像相似，而独立采样的 R-FGSM 状态则改变更新轨迹。碰撞量刻画了所选配置下得到的输出分布。

附录 D　IND-CPA 优势界与查询限制

A. 参考分布与转录偏差

令 $N = |\mathcal{M}|$，$\pi(k) = \Pr[\mathrm{KeyGen}() = k]$，并定义

$$\bar{p}_k(c) = \frac{1}{N} \sum_{u \in \mathcal{M}} p_{k,u}(c). \tag{36}$$

参考预言机独立地从 $\bar{p}_k$ 中采样每个输出，忽略所请求的消息。

对于具有相异 c_i 且正似然低于的转录 $T_j = ((m_1, c_1), \ldots, (m_j, c_j))$，定义

$$\eta_q = \max_{\substack{T_j \text{ 无碰撞} \\ 1 \le j \le q}} \left| \frac{\sum_{k \in \mathcal{K}} \pi(k) \prod_{i=1}^{j} p_{k,m_i}(c_i)}{\sum_{k \in \mathcal{K}} \pi(k) \prod_{i=1}^{j} \bar{p}_k(c_i)} - 1 \right|. \tag{37}$$

对于挑战条目，m_i 仅表示实际消息 m_b 以计算记录似然。

B. 混合游戏

令 G_0 为真实的 IND-CPA 游戏。正确性意味着 $p_{k,u}(c) > 0 \Rightarrow \mathrm{DEC}_k(c) = u$。因此，对于固定密钥，不同消息具有不相交的成功输出支撑，并且

$$p_{k,m}(c) = N \bar{p}_k(c) \mathbf{1}[\mathrm{DEC}_k(c) = m], \tag{23}$$

$$\Pr_{c \leftarrow \bar{p}_k}[\mathrm{DEC}_k(c) = m] = \frac{1}{N}. \tag{38}$$

在 G_1 中，每个对 m 的请求，包括对 m_b 的挑战请求，都从以 $\mathrm{DEC}_k(c) = m$ 为条件的 $\bar{p}_k$ 中采样。其输出律恰好是 $p_{k,m}$，因此 $G_0 \equiv G_1$。

在 G_2 中，每个请求均匀地从 $\mathcal{M}$ 中采样 u，并返回一个独立的 $c \leftarrow \mathrm{ENC}_k(u)$。每个输出因此服从 $\bar{p}_k$。固定对手的随机性和挑战比特，对于固定顺序的记录，自适应查询选择因子相互抵消。因此，

$$\frac{\Pr[G_1 : T_j]}{\Pr[G_2 : T_j]} = \frac{\sum_k \pi(k) \prod_{i=1}^{j} p_{k,m_i}(c_i)}{\sum_k \pi(k) \prod_{i=1}^{j} \bar{p}_k(c_i)}. \tag{39}$$

每个真实记录都具有正参考似然。因此，式 37 将无碰撞贡献的统计距离上界限制为 $\eta_q/2$，包括在自适应消息选择下。

C. 重复输出与证明完成

令 Coll 表示至多 q 个生成输出中的重复输出。在 G_1 中，不同消息的输出不能重合。对于 $i < j$，以密钥、对手随机性、挑战比特以及输出 i 之前的历史为条件。记 $p(c) = p_{k,m_i}(c)$，并令 $a_c \in [0,1]$ 为请求 j 发生且目标为 m_i 的条件概率，给定 $c_i = c$。请求 j 处的新随机性给出

$$\Pr_{G_1}[c_i = c_j] \le \sum_c p(c) a_c p(c) \le \sum_c p(c)^2 \le \varepsilon_{\text{prob}}. \tag{40}$$

在 G_2 中，固定密钥支撑的不相交性给出

$$\sum_c \bar{p}_k(c)^2 = \frac{1}{N^2} \sum_{m \in \mathcal{M}} \sum_c p_{k,m}(c)^2 \le \frac{\varepsilon_{\text{prob}}}{N}. \tag{41}$$

联合界给出 $\Pr_{G_s}[\text{Coll}] \le \binom{q}{2}\varepsilon_{\text{prob}}$，其中 $s \in \{1,2\}$。结合无碰撞和重复输出贡献，

$$\begin{aligned} \Delta(G_1, G_2) &\le \frac{\eta_q}{2} + \frac{\Pr_{G_1}[\text{Coll}] + \Pr_{G_2}[\text{Coll}]}{2} \\ &\le \frac{\eta_q}{2} + \binom{q}{2}\varepsilon_{\text{prob}}. \end{aligned} \tag{42}$$

这里 Δ 表示统计距离。对手在 G_2 中的视图独立于 b。由于 $G_0 \equiv G_1$，相同的界适用于真实游戏中的优势，从而证明定理 1。

D. 可接受的生成查询限制

选择非负预算 $\varepsilon_{\text{mix}}, \varepsilon_{\text{col}}$，其中 $\varepsilon_{\text{sec}} = \varepsilon_{\text{mix}} + \varepsilon_{\text{col}} < 1/2$。如果

$$\frac{\eta_Q}{2} \le \varepsilon_{\text{mix}}, \quad \binom{Q}{2}\varepsilon_{\text{prob}} \le \varepsilon_{\text{col}}, \tag{43}$$

则整数生成查询限制 $Q \ge 1$ 是可接受的。

由式 37，增加查询限制会扩大取最大值的记录集合。因此 η_q 是非递减的，对于 $q \ge 1$，$\binom{q}{2}\varepsilon_{\text{prob}}$ 也是非递减的。对于每个 $1 \le q \le Q$，

$$\frac{\eta_q}{2} + \binom{q}{2}\varepsilon_{\text{prob}} \le \varepsilon_{\text{mix}} + \varepsilon_{\text{col}} = \varepsilon_{\text{sec}}, \tag{44}$$

这证明了式 18。

这通过诱导分布直接定义了允许的限制，而没有规定 η_q 的增长模型。它不需要选择最大的可接受限制。如果没有 $Q \ge 1$ 满足式 43，则该界不能证明所选优势预算

是合理的。

附录 E　IND-CCA1 优势界与恢复限制

A. 同密钥与分裂密钥预言机游戏

两个游戏都采样 $k \leftarrow \mathrm{KeyGen}()$ 用于生成。分裂密钥游戏还采样一个独立的 $\bar{k} \leftarrow \mathrm{KeyGen}()$，并在整个游戏过程中固定。区分者可以交错进行生成和恢复查询，直到它关闭恢复阶段；此后仅允许生成查询。这些辅助游戏没有外部挑战比特。

维护一个由对 (c, m) 组成的生成表 $\mathrm{T}_{\mathrm{enc}}$，以及一个包含对每个恢复输入首次响应的恢复表 $\mathrm{T}_{\mathrm{dec}}$。对于 $s \in \{\mathrm{same}, \mathrm{split}\}$，令 $k_{\mathrm{same}} = k$ 且 $k_{\mathrm{split}} = \bar{k}$。恢复查询按以下顺序处理：

$$\mathrm{GameDec}_s(x) = \begin{cases} y, & (x, y) \in \mathrm{T}_{\mathrm{dec}}, \\ m, & (x, m) \in \mathrm{T}_{\mathrm{enc}}, \\ \mathrm{DEC}_{k_s}(x), & \text{否则.} \end{cases} \tag{45}$$

将每个首次恢复响应存储在 $\mathrm{T}_{\mathrm{dec}}$ 中。重复输入保留其缓存响应，即使它们后来作为生成输出出现。记 $P_s^{\mathcal{D}} = \Pr[\mathrm{Game}_s^{\mathcal{D}} = 1]$ 并定义

$$\delta_{\mathrm{dec}}(q, q_d) = \sup_{\mathcal{D}} \left| P_{\mathrm{same}}^{\mathcal{D}} - P_{\mathrm{split}}^{\mathcal{D}} \right|, \tag{46}$$

其中 $\mathcal{D}$ 遍历概率多项式时间区分者，它们在关闭恢复阶段前最多接收 q 个生成输出并最多进行 q_d 次恢复查询。

B. 归约到 IND-CPA

构造一个 IND-CPA 对手 $\mathcal{A}$，它运行 $\mathcal{A}'$，将其生成查询转发给 CPA 预言机，并将其挑战对转发给 CPA 挑战者。它独立采样 $\bar{k}$，并使用式 45 中的分裂密钥规则和本地表回答挑战前恢复查询。挑战前生成消息对模拟器已知。未知的挑战消息不需要，因为恢复查询在挑战前结束。

为了将此模拟与真实的 CCA1 游戏进行比较，为辅助游戏构造一个区分者 $\mathcal{D}$。它运行 $\mathcal{A}'$ 并转发其预言机请求。当 $\mathcal{A}'$ 提交 (m_0, m_1) 时，它采样 $b \leftarrow \{0, 1\}$，关闭恢复阶段，并获得 m_b 的一个生成输出作为挑战。它输出 $1[b' = b]$。此挑战生成调用包含在 q 中。

令 P_{same} 和 P_{split} 为所得成功概率。正确性和确定性恢复使同密钥视图与真实 CCA1 视图相同，而分裂密钥视图是 CPA 模拟。式 46 给出 $|P_{\mathrm{same}} - P_{\mathrm{split}}| \le \delta_{\mathrm{dec}}(q, q_d)$。

因此，

$$\begin{aligned}\mathrm{Adv}^{\mathrm{IND-CCA1}}_{\mathcal{A}'} &= |P_{\mathrm{same}} - 1/2| \\ &\le |P_{\mathrm{split}} - 1/2| + \delta_{\mathrm{dec}}(q, q_d) \\ &= \mathrm{Adv}^{\mathrm{IND-CPA}}_{\mathcal{A}} + \delta_{\mathrm{dec}}(q, q_d).\end{aligned} \tag{47}$$

代入定理 1 即证明式 19。

C. 命中事件之外的似然偏差

固定区分者的随机性和一个完整的有序转录 τ，包括恢复阶段的关闭。提取记录

$$\begin{aligned}T_E(\tau) &= ((m_1, c_1), \ldots, (m_e, c_e)), \quad e \le q, \\ T_D^{\circ}(\tau) &= ((x_1, y_1), \ldots, (x_h, y_h)), \quad h \le q_d.\end{aligned} \tag{48}$$

第二条记录仅包含首次非重放恢复查询：重复输入以及首次查询时已记录为生成输出的输入被排除。令

$$\begin{aligned}L_E(k) &= \prod_{i=1}^{e} p_{k,m_i}(c_i), \\ L_D(k) &= \prod_{j=1}^{h} \mathbf{1}[\mathrm{DEC}_k(x_j) = y_j].\end{aligned} \tag{49}$$

定义 Hit 为 $T_D^{\circ}(\tau)$ 中的输入随后作为生成输出返回的事件。在该事件之外，同密钥与分裂密钥的似然比为

$$R(\tau) = \frac{\sum_k \pi(k) L_E(k) L_D(k)}{\left(\sum_k \pi(k) L_E(k)\right)\left(\sum_k \pi(\bar{k}) L_D(\bar{k})\right)}. \tag{50}$$

对于查询限制 q, d，定义

$$\zeta_{q,d} = \max_{\substack{\tau \text{ 在 Hit 外可达} \\ |T_E(\tau)| \le q,\ |T_D^{\circ}(\tau)| \le d \\ \text{分裂密钥似然} > 0}} |R(\tau) - 1|. \tag{51}$$

对于完整的有序转录，自适应查询选择因子相互抵消。每个正的同密钥似然都有正的分裂密钥似然。因此，Hit 之外的转录对统计距离的贡献至多为 $\zeta_{q,q_d}/2$。

D. 命中概率与恢复查询限制

定义 $\mu_{\mathrm{enc}} = \max_{k,m,c} p_{k,m}(c)$。由于 $p_{k,m}(c)^2 \le \sum_z p_{k,m}(z)^2 \le \varepsilon_{\mathrm{prob}}$，

$$\mu_{\mathrm{enc}} \le \sqrt{\varepsilon_{\mathrm{prob}}}. \tag{52}$$

对于每个较早的首次非重放恢复输入和每个较晚的生成输出，新的生成随机性将条件命中概率限制在 μ_{enc} 内。这在两个游戏的自适应查询选择下都成立。因此，联合界给出

$$\Pr[\mathrm{Game}_s : \mathrm{Hit}] \le q q_d \mu_{\mathrm{enc}}, \quad s \in \{\mathrm{same}, \mathrm{split}\}. \tag{53}$$

结合 Hit 内部和外部的贡献，

$$\begin{aligned} \delta_{\mathrm{dec}}(q, q_d) &\le \frac{\zeta_{q,q_d}}{2} + \frac{1}{2} \sum_{s \in \{\mathrm{same},\mathrm{split}\}} \Pr[\mathrm{Game}_s : \mathrm{Hit}] \\ &\le \frac{\zeta_{q,q_d}}{2} + q q_d \mu_{\mathrm{enc}} \\ &\le \frac{\zeta_{q,q_d}}{2} + q q_d \sqrt{\varepsilon_{\mathrm{prob}}}. \end{aligned} \tag{54}$$

从附录 D 固定一个可接受的生成查询限制 $Q \ge 1$，并选择 $\varepsilon_{\mathrm{dec}} \ge 0$ 使得 $\varepsilon_{\mathrm{sec}} + \varepsilon_{\mathrm{dec}} < 1/2$。如果

$$\frac{\zeta_{Q,Q_d}}{2} + Q Q_d \mu_{\mathrm{enc}} \le \varepsilon_{\mathrm{dec}}, \tag{55}$$

则整数恢复查询限制 $Q_d \ge 0$ 是可接受的。式 51 中的最大值是在嵌套转录集合上取的，因此 $\zeta_{q,d}$ 在两个查询限制中都是非递减的。对于 $1 \le q \le Q$ 和 $q_d \le Q_d$，

$$\begin{aligned} \delta_{\mathrm{dec}}(q, q_d) &\le \frac{\zeta_{q,q_d}}{2} + q q_d \mu_{\mathrm{enc}} \\ &\le \frac{\zeta_{Q,Q_d}}{2} + Q Q_d \mu_{\mathrm{enc}} \le \varepsilon_{\mathrm{dec}}. \end{aligned} \tag{56}$$

结合式 18，这证明了式 20。在没有恢复查询时，$L_D(k) = 1$，所以 $\zeta_{q,0} = 0$；两个预言机游戏重合，且 $\delta_{\mathrm{dec}}(q, 0) = 0$。因此 $Q_d = 0$ 总是恢复仅生成基线，而正的恢复允许量需要相应的分布条件。